

구조·시간·인식 그래프 RAG를 활용한 대한민국 항공안전법령 질의응답 신뢰성 검증 연구

A Validation Study of Structure-Aware Temporal Graph RAG for Reliable Question Answering over Korean Aviation Safety Regulations

ABSTRACT

This study validates Structure-Aware Temporal Graph Retrieval-Augmented Generation for question answering over Korean aviation safety regulations applicable to flight crew of fixed-wing air transport operators. Four systems are compared under controlled conditions: Current Vector RAG, All-Version Naive RAG, Temporal-Filtered Vector RAG, and SAT-Graph RAG. The benchmark is separated into a 20-question pilot set for configuration and an 80-question hold-out set for final evaluation. Retrieval quality, version accuracy, answer quality, citation quality, hallucination, refusal behavior, latency, token use, and cost are measured separately, and failures are traced to retrieval, temporal filtering, relation expansion, generation, or citation stages. **Insert the principal numerical findings, confidence intervals, effect sizes, and conclusion after the hold-out experiment (실험 후에 작성 필요)**

Key Words : aviation safety law(항공안전법), retrieval-augmented generation(검색증강생성), legal RAG(법률 검색증강생성), temporal knowledge graph(시간적 지식그래프), version-aware retrieval(버전인식검색), regulatory technology(규제기술)

I. 서 론

1.1. 연구배경과 필요성

항공운항의 안전성과 적법성은 단일 규정의 확인만으로 확보되지 않는다. 항공운송사업자의 운항승무원 자격, 교육훈련, 최근비행경험, 항공 신체검사, 승무시간과 비행근무시간, 피로관리, 운항통제, 비행계획, 연료, 기상, 접근·착륙 및 복행에 관한 의무는 항공안전법, 같은 법 시행

령과 시행규칙, 별표, 운항기술기준 및 승인문서에 분산되어 있다. 실무자는 질문의 기준일에 유효한 조문을 찾는 동시에 상위법과 하위기준의 연결, 위임관계, 예외조건 및 승인범위를 함께 판단해야 한다.

법령 검색에서 의미적 유사성만 고려하면 현재 조문과 폐지·개정된 과거 조문이 함께 반환될 수 있다. 생성모델은 검색된 근거가 시간적으로 무효하더라도 이를 자연스럽고 확정적인 문장으로 재구성할 가능성이 있다. 따라서 법령 질의응답의 신뢰성은 문장 수준의 의미적 관련성뿐 아니라 법령 위계, 적용시점, 개정정보, 상호참조 및 원문 출처(provenance)를 함께 고려해야 한다.

RAG는 생성모델의 매개변수 지식과 외부 검색지식을 결합하여 지식집약적 과업에서 최신성

Received : 00. Apr. 2024. Revised : 00. Oct. 2024.

Accepted : 00. Dec. 2024

* 이파일은 심사위원이 확인하는 파일로 저자 인적사항은 별도의 Title page 파일에 명기해주시고, 이 파일에는 기입하지 않습니다.

과 근거 활용 가능성을 확장하였다(Lewis et al., 2020). 그러나 법률문서는 일반 문서와 달리 규범적 위계, 위임, 상호참조, 개정·폐지와 시행일을 갖는다. 평면적인 벡터 검색은 이러한 구조와 통시성을 충분히 반영하지 못할 수 있다. SAT-Graph RAG는 법규의 구성요소와 버전, 시간정보 및 법적 관계를 명시적으로 모델링하여 이를 보완하려는 접근이다(de Martim, 2025). VersionRAG 역시 변화하는 기술문서에서 버전 인식 검색의 필요성을 제시하였지만, 그 결과를 항공안전법령에 직접 일반화하기 위해서는 별도의 실증 검증이 필요하다(Huwiler et al., 2025).

항공은 안전중요 영역이므로 평균 답변정확도만으로 시스템 신뢰성을 판단하기 어렵다. 항공 AI에서는 인간 중심 신뢰성, 설명가능성, 학습보증 및 인증체계 안에서의 기능·성능 검증이 강조된다(EASA, 2023; EASA, 2026; FAA, 2026). 따라서 항공법령 RAG는 답변의 정확성뿐 아니라 어느 원문, 조문, 버전 및 시행일에서 근거가 도출되었는지를 추적할 수 있어야 하며, 근거가 부족하거나 충돌하는 경우 판단불가 또는 추가 검증 필요를 표시하는 안전장치가 된(fail-safe) 특성을 갖추어야 한다.

1.2. 연구목적

본 연구의 목적은 대한민국 항공안전법령의 운항승무원 규정에서 버전 인식과 법령구조 인식이 검색 및 생성 성능에 미치는 효과를 정량적으로 검증하는 것이다. 이를 위해 현재 유효본만을 대상으로 하는 벡터 RAG, 모든 버전을 시간필터 없이 검색하는 naive RAG, 질문일자 기반 시간필터를 적용한 벡터 RAG, 그리고 시간필터와 법령 위계·상호참조·위임·승인의존 관계를 함께 활용하는 SAT-Graph RAG를 비교한다. 특히 System B와 C의 차이를 통해 시간필터의 순효과를, System C와 D의 차이를 통해 법령구조 및 관계탐색의 추가효과를 분리하여 추정한다.

1.3 연구문제 및 가설

RQ1. 대한민국 항공안전법령의 구조적·시간적

특성은 일반 Vector RAG의 법령 검색 및 질의 응답 성능에 어떠한 영향을 미치는가?

RQ2. Temporal Filtering을 적용한 System C는 모든 버전을 혼합하여 검색하는 System B에 비해 retrieval accuracy와 temporal consistency를 향상시키는가?

RQ3. Structure-Aware Temporal Graph RAG인 System D는 Temporal-Filtered Vector RAG인 System C에 비해 retrieval accuracy, evidence completeness 및 generated-answer performance를 향상시키는가?

RQ4. 질문이 요구하는 계층적(Hierarchical), 규정 간(Cross-Regulatory), 승인 의존(Approval) 및 시간적(Temporal) 복잡성이 증가할수록 temporal/structure-aware retrieval의 상대적 효과가 증가하는가?

H1. 시간필터를 사용하는 System C와 D는 System B보다 Version Accuracy와 시간정합성이 높을 것이다.

H2. 법령 위계와 관계를 활용하는 System D는 System C보다 다중근거 질문의 Hit@K, nDCG@K 및 인용완전성이 높을 것이다.

H3. System D는 System A부터 C보다 전체 답변정확성이 높고 금지 버전 인용률과 환각률이 낮을 것이다.

H4. System D의 지연시간과 계산비용은 증가할 수 있으나 정확도 향상 대비 비용은 사전에 정의한 실무 허용범위 안에 있을 것이다.

H5. 기존 법률·정책 문서를 대상으로 한 선행 연구에서 Structure-Aware Temporal Graph RAG가 높은 성능향상을 보였음에도 불구하고, 대한민국 항공안전법령에서는 그 상대적 성능향상이 제한적일 것이다. 이는 항공안전법령이 법률 - 시행령 - 시행규칙 - 별표 - 운항기술기준으로 이어지는 다층적 규범구조, 규정 간 교차참조, 승인·인가 의존관계, 기술적 요건 및 복수의 시간적 유효성 정보를 동시에 포함하기 때문이며, 이러한 특성으로 인해 범용 SAT-Graph RAG만으로는 일부 질의에서 충분한 검색 정확도와 근거 완전성을 확보하기 어려울 것이다.

1.4 연구범위와 차별성

연구범위는 항공기를 사용한 항공운송사업의 고정의 운항승무원 규정으로 한정한다. 객실승무원, 정비, 항공교통관제 및 회전익 고유규정은 원칙적으로 제외한다. 내용 범위는 자격, 교육훈련, 최근비행경험, 항공신체검사, 승무시간, 비행근무시간, 피로, 운항통제, 비행계획, 연료, 기상, 접근, 착륙 및 복행이다. 구체적인 법령 corpus와 기준일은 데이터 동결기록을 따른다.

본 연구의 차별성은 다음과 같다. 첫째, 기술 문서 중심의 VersionRAG와 개념검증 중심의 SAT-Graph를 한국 항공안전법령이라는 전문적 안전규제 영역에서 실증한다. 둘째, corpus 차이와 시간필터 차이, 그래프 구조 차이를 단계적으로 통제하여 시간효과와 구조효과를 분리한다. 셋째, 검색과 생성을 분리 평가하고 정답 버전뿐 아니라 forbidden version을 Gold Standard에 포함하여 그럴듯한 시대착오적 오답의 발생경로를 추적한다. 넷째, 데이터 cutoff, 원문 hash, config hash, 실행로그 및 결과 manifest를 보존하여 재현성과 감사가능성을 확보한다.

II. 이론적 배경 및 선행연구

2.1. RAG와 법률 문서 검색

RAG는 질문과 관련된 외부 문서를 검색한 뒤 해당 근거를 생성모델의 입력에 결합한다(Lewis et al., 2020). 외부지식의 갱신과 출처제시에는 유리하지만, 검색기가 잘못된 근거를 반환하면 생성모델이 해당 오류를 유창하게 재생산할 수 있다. 법률 RAG의 중단간 평가는 검색과 추론·생성 구성요소를 분리해야 하며(Butler and Butler, 2026), 문서 단위의 거친 검색보다 답변에 필요한 최소 충분 법률구간을 정확하게 반환하는지를 평가해야 한다(Pipitone and Alami, 2024).

GraphRAG는 문서에서 추출한 개체와 관계 및 커뮤니티 요약 활용하여 대규모 corpus의 전역 질문에 대응한다(Edge et al., 2024). 그러나 일반 GraphRAG의 개체·관계가 LLM 추출에 의존할 경우 법령이 명시한 공식 위계와 규범관계를 보장하기 어렵다. 법령 RAG에서는 생성된

관계보다 공식 구조와 원문 provenance가 우선되어야 하며, 그래프는 원문을 대체하는 지식원이 아니라 검색경로와 검증계층으로 활용되어야 한다.

이러한 원칙은 규정영역이 다른 항공 정비매뉴얼 검색 연구에서도 동일하게 확인된다. 인증된 정비매뉴얼의 원문을 기술자가 직접 열람하도록 요구하는 규제환경에서는 LLM이 제작성난 텍스트를 최종 근거로 제시할 수 없으므로, LLM은 후보 절차의 재순위화(re-ranking)에만 관여하고 절차 내용 자체는 생성하거나 수정하지 않도록 설계되며, LLM이 유효한 출력을 반환하지 못하는 경우 검증된 기저 밀집검색(dense retrieval) 순위로 대체하는 fail-safe fallback을 둔다(Jo, 2026). 본 연구의 SAT-Graph RAG 역시 이와 같은 원칙을 채택하여, 그래프 확장으로 얻어진 근거는 원문 pointer와 유효기간을 검증한 후에만 최종 근거로 채택하며 검증되지 않은 LLM 생성 관계는 사용하지 않는다(3.6.4 참조).

2.2 버전인식과 시간 지식그래프

법령의 시간정합성은 문서 작성일을 비교하는 문제와 다르다. 공포일과 시행일이 다를 수 있고, 부칙에 따라 일부 조문만 다른 날짜에 시행되며, 개정 전후 조문이 경과조치에 의해 병존할 수 있다. Temporal KGQA는 사실과 관계에 시작·종료 시점을 부여하여 질문시점에 유효한 지식을 선택하는 접근을 제공한다(Saxena et al., 2021). VersionRAG는 문서, 버전, 콘텐츠 및 변경계층을 통해 버전 민감 질문을 처리하였고 기술문서 질의응답에서 버전 인식 검색의 가능성을 제시하였다(Huwiler et al., 2025). 다만 법령은 규범적 효력, 위임, 부칙 및 승인범위를 포함하므로 기술문서와 다른 검증설계가 필요하다.

2.3 구조 시간 인식 그래프

SAT-Graph는 Norm, Component, Temporal Version 및 법적 action을 명시적으로 모델링한다(de Martim, 2025). 본 연구에서는 법률, 시행령, 시행규칙, 별표 및 운항기술기준의

Table 1. Key Prior Studies and Their Relevance to the Present Study

연구	주요 기여	한계 또는 연구 공백	본 연구 적용
Lewis et al. (2020)	외부 비매개 지식과 생성모델을 결합한 RAG 제시	법령의 시간·위계 구조 미반영	4개 시스템의 공통 RAG 골격
Edge et al. (2024)	그래프 커뮤니티 기반 전역검색	공식 규범관계보다 추출 관계 중심	일반 GraphRAG와 SAT-Graph 구분
Pipitone and Alami (2024)	최소 충분 법률구간의 정밀검색 평가	버전·다중법원 구조는 제한적	Gold evidence와 검색·생성 분리평가
Huwiler et al. (2025)	버전문서 QA와 버전 인식 경로	기술문서 중심, 법적 효력 미검증	시간필터와 버전정확도 설계
de Martim (2025)	법률의 위계·시간·action을 모델링	정량 대규모 검증이 제한적	항공법령에 구현 후 4계열 정량비교
Schlichting et al. (2025)	실시간 운항문맥과 문서 RAG 결합	시뮬레이션 연구플랫폼	후속 context-aware RAG의 근거
Iyengar et al. (2026)	항공안전 KG를 RAG 근거계층으로 활용	관계추출·하이브리드 검색 추가 필요	법령 그래프의 provenance·traceability

parent-child 관계, 조문 간 cites와 delegates-to 관계, 버전 간 amended-by, supersedes 및 repeals 관계, 그리고 필요한 경우 approval dependency를 그래프에 표현한다. 각 노드는 원문 pointer와 유효기간을 유지하며, 질문일자에 유효한 노드를 먼저 제한한 후 관련 구조를 확장한다.

2.4 법률 및 항공분야 RAG 평가

LegalBench는 법적 reasoning을 다양한 유형으로 구분하여 단일 평균점수가 가릴 수 있는 과업차이를 제시하였다(Guha et al., 2023). LegalBench-RAG는 질의와 근거 쌍을 이용해 검색구간의 정밀도를 평가하였고(Pipitone and Alami, 2024), Legal RAG Bench는 전문가 수준의 복합질문을 활용한 종단간 성능평가를 제안하였다(Butler and Butler, 2026). 본 연구는 이를 참고해 현행, 과거, 개정비교, 위임·다중근거, 수치·한도, 미시행 및 답변불가 질문으로 평가문항을 증화한다. (연구 절차의 세부 단계는 표 1 참조)

항공 규정 도메인에서도 RAG 적용 연구가 최근 축적되고 있으며, 특히 두 연구가 본 연구의 설계에 직접적인 시사점을 제공한다.

첫째, 중국 민항 감항규정을 대상으로 한 RAG 연구는 표준 chunking 대신 조문의 계층 구조를 명시적으로 반영한 semantic-aware chunking과 metadata 결합, 이단계 "검색 - 재순위화(retrieval - re-ranking)" 기법을 단계적으로

추가하며 성능을 측정하였다. 그 결과 평면적 벡터 RAG의 전체 정확도 42.32%에서, 구조화 청킹과 메타데이터 결합만으로 60.19%로, 하이브리드 검색 결합 시 66.49%로, cross-encoder 재순위화까지 결합 시 70.19%로 단계적으로 향상되었다(Zheng et al., 2025). 이는 법령의 계층·구조 정보를 명시적으로 활용하는 것이 평면적 의미 검색 대비 유의미한 성능 향상을 가져올 수 있음을 실증하며, 본 연구가 System A에서 System D로 이행하며 시간정보와 구조·관계 정보를 단계적으로 추가하는 비교설계를 채택한 근거가 된다. 다만 해당 연구는 조문의 시간적 버전 관리(개정·폐지·시행일)를 다루지 않았고 중국 민항규정이라는 단일 법체계만을 대상으로 하였다는 한계가 있어, 시간축을 명시적으로 다루는 본 연구와는 구별된다.

둘째, 항공 의사결정지원 LLM 연구는 평균 답변정확도만으로는 법령 RAG 시스템의 안전성을 온전히 평가할 수 없음을 보여준다. FAA 공개문서를 대상으로 한 RAG 도구 평가에서, 도구 없이 사전학습 지식만으로 답한 baseline GPT-4o가 규정질문의 95%를 정확히 답한 반면, RAG 기반 시스템은 색인된 문서 범위 밖 질문 비율(corpus coverage gap, 29.8%)로 인해 74%에 그쳤다. 그러나 baseline GPT-4o는 존재하지 않는 하이재킹 트랜스폰더 코드를 사실처럼 답하는 환각을 보인 반면, RAG 시스템은 코퍼스에 없는 내용에 대해 근거부족으로 답변을 거절하였고, 저자들은 이러한 거절 행동을 도메인특

Table 2 Overall Research Procedure

단계	주요작업	동결 및 산출물
1 데이터 수집	공식 법령·고시 수집, provenance 기록	Raw corpus, 수집 manifest
2 전처리·구조화	정제, 계층·버전·유효기간 부여	Clean corpus, QA report
3 TT21 청킹 비교	후보별 품질·검색성능 비교	최종 청킹 config
4 시스템 구축	A부터 D까지 동일 통제조건으로 구현	Index, graph, system manifest
5 파일럿	20문항으로 기능·설정 점검	동결 prompt·top-k·평가기준
6 Hold-out 본실험	80문항 블라인드 실행	원시 결과와 평가표
7 분석	통계, 오류, 비용 및 민감도 분석	결과표·그림·재현 패키지

화 의사결정지원 시스템에 더 안전한(safer) 행동으로 평가하였다(Sharif Rohani et al., 2026). 이 결과는 단일 정답률 지표만으로는 법령 RAG 시스템의 신뢰성을 평가할 수 없으며, 답변정확성과 환각률·거절정확도를 분리하여 측정해야 함을 시사한다. 본 연구가 3.8에서 답변정확성과 별도로 환각률과 거절정확도를 독립된 지표로 설계한 것은 이러한 문제의식을 반영한 것이다.

항공분야에서 LeRAAT는 실시간 비행상태와 기상, 항공기별 매뉴얼 및 규정자료를 결합한 조종사 지원 연구플랫폼을 제시하였다(Schlichting et al., 2025). 항공안전 지식그래프 연구는 LLM을 지식추출과 답변생성에 활용되 검증 가능한 지식그래프를 중간 근거계층으로 두는 접근을 제안하였으며, 그 배경으로 파인튜닝된 도메인특화 LLM조차 기술질의회에서 15~25%의 환각률을 보이고 DO-178C 및 ISO/IEC/IEEE 8800이 요구하는 추적가능성을 충족하지 못한다는 점을 지적하였다(Iyengar et al., 2026). 이러한 연구는 항공 규제정보 시스템이 단순 키워드 검색에서 근거 기반 의사결정 지원으로 이동하고 있으며, 동시에 구조화된 근거계층과 분리된 안전성 지표 없이는 그 신뢰성이 충분히 담보되지 않음을 보여준다.

2.5 연구공백과 분석틀

선행연구는 법률 RAG의 검색정확도, 변화 문서의 버전 인식, 법률구조의 그래프 표현, 항공안전 지식그래프의 가능성을 각각 제시하였고, 최근에는 항공 규정 도메인에서 구조 인식 검색의 단계적 효과(Zheng et al., 2025)와 답변정확성-안전성 지표를 분리해야 할 필요성(Sharif Rohani et al., 2026) 또한 제시되었다. 그러나 한국 항공안전법령에서 시간필터의 효과와 법령

구조 그래프의 추가효과를 동일 조건에서 분리한 실증연구는 제한적이다. 본 연구는 동일 질문이 네 시스템에 반복 투입되는 paired design을 사용하고, 검색·시간·관계·생성의 각 단계를 분리하여 성능과 실패원인을 검증한다.

III 연구설계 및 방법

3.1 연구설계개요

본 연구는 네 RAG 시스템의 성능을 동일한 평가문항에 반복 측정하는 비교검증연구이다. 독립변수는 검색시스템 유형이며, 종속변수는 검색성능, 시간정합성, 생성품질 및 운영효율이다. 질문, 원문 corpus, 최종 청킹 조건, 임베딩과 reranker, 생성모델, prompt, top-k 및 실행 환경은 가능한 한 동일하게 고정한다. 시스템 간 차이는 색인 대상 버전, 질문시점 필터 및 법령관계 그래프의 활용 여부로 제한한다.연구 절차는 데이터 수집부터 결과 분석까지 총 7단계로 진행되며, 각 단계의 주요작업과 동결·산출물은 <Table 2>와 같다.

3.2 연구대상 및 데이터 수집

원문 수집은 국가법령정보센터와 국토교통부 공식 공개자료를 대상으로 완료하였다. 수집된 99개 파일은 항공안전법 23개 XML, 항공안전법 시행규칙 36개 XML, 운항승무원 자격심사 관련 행정규칙 8개 XML, 고정익항공기 운항기술기준 28개 XML과 현행 전문 PDF 1개, 시행규칙 별표 4·18·36 PDF 3개로 구성된다. 각 파일에는 source ID, 법령·행정규칙 ID, 문서명, 공포·발령일, 시행일, 수집시각, 출처 URL, 파일경로, 크기 및 SHA-256을 부여하였다. TT08에서 99개

Table 3 Data Collection Scope by Aviation Law and Technical Standard

법령 기준유형	수집 및 선별범위	포함단위	공식출처	원문 수집량
항공안전법	운항승무원·운항규칙 관련 현행·연혁	조·항·호·목·부칙	국가법령정보센터	23 XML
항공안전법 시행령	직접 적용범위 검토 후 대상 없음	-	국가법령정보센터	0
항공안전법 시행규칙	자격·훈련·운항·근무시간 관련 현행·연혁	조·항·호·목·부칙	국가법령정보센터	36 XML
시행규칙 별표 4·18·36	운항승무원·운항규정·승무시간 관련 항목	별표·표·세부항	국가법령정보센터	3 PDF
운항승무원 자격심사 관련 규정	자격심사·기량·최근경험 관련 현행·연혁	조·항·별표	국가법령정보센터	8 XML
고정익항공기 운항 기술기준	국제항공운송사업자 운항·훈련·자격 관련 기준	section·requirement	국토교통부	28 XML+1 PDF

Table 4 Dataset Construction Results

구분	수집	제외 혹은 오류	최종	비고
Raw 원문	99 파일	오류 0	95 XML+4 PDF	FRZ-TT09-001
Semantic document version	95 physical XML	alias 2쌍 통합	93	동일본 병합
계층 component	239,509	행 손실 0	239,509	TT11·TT12
Provision version	212,970	interval 오류 0	212,970	TT14·TT15
CONTENT Text Unit	법령본문 6,822	운항요건 14,135	20,957	TT21 입력
법적 관계	875	coverage gap 6	875	TT19

파일의 checksum과 크기를 전수 재계산했으며 mismatch, 0-byte, XML syntax 오류 및 손상 PDF는 모두 0건이었다. XML 95건은 전부 파싱에 성공했고 PDF 4건도 preflight를 통과하였다. Current endpoint와 latest history가 동일한 2개 exact-hash alias 쌍은 의도된 중복으로 문서화하고 동일 semantic document version으로 연결하였다.

본 연구의 데이터 범위는 대한민국에서 국제항공운송사업을 수행하는 고정익 항공운송사업자에게 적용되는 항공안전 법령·기준 가운데 운항승무원의 자격과 운항업무에 직접 관련되는 규정으로 한정하였다. 수집대상은 항공안전법, 항공안전법 시행규칙, 시행규칙 별표 4·18·36, 운항승무원 자격심사 관련 행정규칙 및 고정익 항공기를 위한 운항기술기준이다. 항공안전법 시행령은 법령체계와 위임관계를 검토하였으나 최종 범위에 직접 해당하는 원문이 없어 수집건수는 0건이었다. 내용범위는 조종사 자격, 교육훈련, 최근비행경험, 항공신체검사, 승무시간·비행근무시간, 피로관리, 운항통제, 비행계획, 연료, 기상, 교체비행장, 접근, 착륙 및 복행으로 확정하였다. 객실승무원, 정비, 항공교통관제, 회

전의 항공기 및 국제항공운송사업자 운항승무원의 의무와 직접 관련되지 않는 조항은 제외하였다. Raw V1은 99개 원문파일(95 XML, 4 PDF)이며, 93개 semantic document version에서 239,509개 계층 component를 파싱하였다. 최종 검색대상은 법적 범위와 검색가능성 기준을 통과한 20,957개 CONTENT Text Unit으로, 법령본문 6,822개와 별표·기술기준의 구조화 요건 14,135개로 구성된다. 이 20,957개는 조문번호의 단순 개수가 아니라 버전·계층·세부요건을 구분한 최종 검색단위이다.

3.3 데이터 전처리와 구조화

전처리는 법적 의미를 바꾸지 않는 형식적 정규화를 상위 원칙으로 완료하였다. 의미, 수치, 단위, 부정표현, 예외조건, 인과관계 및 공식 행정결론은 변경하거나 요약하지 않았다. 수집 원문은 raw_text로 보존하고, cleaned_text에는 공백·줄바꿈·제어문자·호환문자의 정규화와 Unicode NFKC를 적용하였다. TT12에서 239,509개 component 전부를 정제하여 cleaned_components 239,509개를 생성했으며 행 손실은 0건이었다. 67,161개 행에 정규화가 적용

되었고 그중 51,695개 행에서 NFKC 변화가 확인되었으나 의미손실과 법령 상호참조 QA 오류는 각각 0건이었다. 고정 seed의 20개 표본을 원문과 대조한 결과도 모두 통과하였다.

구조화 단위는 norm-document version-component-provision version-text unit-chunk로 확정하였다. TT11 parser는 95개 XML 원문을 4개 norm, 93개 semantic document version 및 239,509개 component로 변환하였다. component는 편·장·절·관·조·항·호·목·별표·서식·기술기준 section과 requirement를 구분하며, stable component_id, parent_component_id, order key, source locator와 원문 pointer를 보존한다. TT14와 TT15에서는 212,970개 provision version에 valid_from, valid_to, status 및 전후 version 연결을 부여하였다. 최종 상태분포는 CURRENT 4,770개, EXPIRED 203,831개, FUTURE-EFFECTIVE 1,704개, SUPERSEDED-AT-EFFECTIVE-BOUNDARY 25개, SUPERSEDED-BEFORE-EFFECTIVE 1개, SUPERSEDED-PRE-EFFECTIVE-COPY 87개 및 SUPERSEDED-SAME-DAY 2,552개였다. invalid interval, 중복 CURRENT 및 premature FUTURE는 모두 0건이었다.

부칙·별표 전용 정제는 TT13에서 완료하였다. 부칙 912개 component를 3,634개 구조화 행으로, 별표 1,856개 component를 354,503개 구조보존 line으로 변환했으며 QA issue는 0건이었다. Cleaning Rules는 FRZ-TT13-001로 동결하였다. TT16에서는 별표 18과 기술기준을 구조화하여 별표 18 요건 1,567개와 운항요건 15,751개를 생성했고, 법적 범위와 검색가능성 조건을 통과한 운항요건은 14,135개였다. 과거 첨부파일만 존재하는 6개 snapshot은 명시적 coverage gap으로 유지하였다.

3.4 청킹비교와 최종 청킹선택

최종 실험에 사용할 청킹 방식은 TT21에서 후보별 기능적 차이와 검색성능을 비교한 후 확정한다. 후보에는 fixed-token, overlap fixed-token, fixed-character, recursive 및

structural 방식이 포함되며, 필요하면 법령의 parent-child 문맥을 보존하는 개선형 structural 방식을 추가한다. 모든 후보는 동일한 정제 corpus에 적용하고, config의 설정값이 실제 runtime splitter로 전달되는지 확인한다. 후보들이 비정상적으로 동일한 청크 수와 경계를 산출할 경우 공통 fallback, 잘못된 dispatcher, 설정 미전달 및 cache 재사용 여부를 점검한다.

후보 평가는 청크 수, token 또는 문자 길이 분포, 너무 짧거나 긴 청크의 비율, 조·항·호 경계 보존율, 표·별표 분절률, 중복률, 정답근거 완전포함률, 파일럿 Hit@K·MRR·nDCG@K, 처리 시간 및 저장용량을 기준으로 한다. 법률문서에서는 평균 길이가 적절하더라도 적용조건이나 예외가 다른 청크로 분리되면 답변 신뢰성이 저하될 수 있으므로 법적 의미단위의 보존을 우선한다.

TT21 후보별 설정, 산출 청크 수, 길이분포, 경계 보존율, 중복률, 파일럿 검색성능과 처리시간을 표로 제시한다 (실험 후에 작성 필요)

최종 선정된 청킹 방식, 선정근거, 제외된 후보의 문제 및 최종 config hash를 기재한다 (실험 후에 작성 필요)

3.5 임베딩 검색 및 재순위화

한국어 법령과 긴 문맥을 처리하기 위해 다국어 dense·sparse·multi-vector 기능을 지원하는 BGE-M3를 임베딩 후보로 설정하였다(Chen et al., 2024). 다만 일반 다국어 benchmark의 성능이 한국 항공법령에서 그대로 재현된다고 가정하지 않고, smoke test와 파일럿 검색평가를 통해 최종 모델을 확정한다. 네 시스템에는 동일한 임베딩 모델, vector normalization, 유사도 함수, 검색 top-k, reranker 및 최종 반환 근거수를 적용한다.

최종 embedding 모델 ID와 revision, 라이브러리 버전, embedding 차원, 최대 token, pooling·normalization, batch size, precision 및 similarity metric을 기재한다 (실험 후에 작성 필요)

reranker 모델 ID와 revision, 초기 검색 후보

Table 5 Key Evaluation Metrics and Measurement Criteria

영역	지표	산출 또는 판정기준
검색	Hit@5, MRR, nDCG@5	Gold 근거의 포함·순위·관련도
시간	Version Accuracy	질문일에 적용되는 정답 version 선택 여부
시간	Forbidden-version rate	금지 version이 검색 또는 인용된 비율
생성	답변정확성·시간정합성	Gold answer 및 기준일과의 일치
인용	인용정확성·완전성	인용의 실제 지지 여부와 필수근거 포함 여부
안전	환각률·거절정확도	근거 없는 주장과 답변불가 처리
효율	시간·token·비용	단계별 latency와 자원소비

Table 6 Configuration and Comparative Purpose of the Four RAG Systems

시스템	색인 Corpus	시간처리	구조 및 관계	비교목적
A Current Vector	기준일 현재 유효본	별도 필터 없음	없음	현행질문 기준선
B All-Version Naive	모든 과거·현재 버전	없음	없음	버전 혼재 위험
C Temporal-Filtered Vector	모든 버전	질문일자 valid interval	없음	시간필터 순효과
D SAT-Graph RAG	모든 버전	질문일자 valid interval	위계·참조·위임·개정·승인의존	구조·관계 추가 효과

수, 재순위화 후보 수, 최종 top-k 및 점수 결합 방식을 기재한다 (실험 후에 작성 필요)

만 검색후보로 허용한다. 기준일이 없는 현행질문에는 사전 정의한 실험 기준일을 적용한다. 시간정보가 모호하거나 충돌할 경우 임의로 확정하지 않고 추가검증 필요를 표시하도록 prompt를 설계한다.

3.6 비교RAG 시스템 구축

3.6.1 System A Current Vector RAG

System A는 실험 기준일 현재 유효한 조문만 색인한다. 질문을 embedding한 후 vector similarity와 reranker로 근거를 선정하고 동일 생성 prompt에 전달한다. 과거시점과 개정비교 질문에 필요한 폐지버전이 corpus에 없으므로 이러한 질문에 구조적 한계가 있다.

3.6.2 System B All Version Naive RAG

System B는 모든 과거·현재 버전을 색인하지만 질문기준일 필터를 적용하지 않는다. 의미적으로 유사한 여러 version이 동시에 검색될 수 있으며, 이를 통해 시간제약이 없는 all-version 검색에서 발생하는 forbidden version 노출과 시간오류를 측정한다.

3.6.3 System C Temporal Filtered Vector RAG

System C는 질문에서 기준일을 추출하거나 명시된 evaluation date를 사용해 $\text{valid_from} \leq \text{query_date} < \text{valid_to}$ 조건을 충족하는 version

3.6.4 System D SAT Graph RAG

System D는 System C와 동일한 시간필터를 적용한 뒤, 검색된 seed component를 중심으로 parent-child, cites, delegates_to, amended_by, supersedes, repeals 및 approval_dependency 관계를 확장한다. 그래프 확장은 사전에 정의한 relation whitelist, 최대 hop, 방향 및 증거예산 안에서 수행한다. 확장된 근거는 원문 pointer와 유효기간을 검증한 후 reranker 또는 deterministic rule로 정렬하며, 검증되지 않은 LLM 생성관계는 최종 근거로 사용하지 않는다.

System D의 실제 node·edge type, 노드 수, 관계 수, 최대 hop, 관계별 확장규칙, conflict 처리 및 graph query를 기재한다 (실험 후에 작성 필요) 네가지 시스템의 생성단계에는 동일한 모델과 prompt를 사용한다. 출력에는 답변, 적용기준일, 법령명, 조·항·호, version 유효성, 인용근거 및 원문링크를 포함하도록 한다. 검색근거가 없거나 충돌하는 경우에는 답변을 추측하지 않고 근거부족 또는 추가검증 필요를 표시하도록 한다.

Table 7 Stratification Plan for Evaluation Questions

유형	핵심추론부담	주요지표	문항 수
현행	실험 기준일 현재 적용규정	Hit@K, 답변정확성	(실험 후 작성)
과거	특정 과거일의 유효 version	Version Accuracy	(실험 후 작성)
개정비교	개정 전후 내용·시행시점 비교	변경근거 완전성	(실험 후 작성)
다중근거	법률·규칙·별표·기준 결합	nDCG, 인용완전성	(실험 후 작성)
수치·한도	시간·횟수·기간의 정확한 추출	수치정확성	(실험 후 작성)
미시행	공포되었으나 아직 시행되지 않은 규정	시간정합성	(실험 후 작성)
답변불가	corpus 밖 사실 또는 근거부족	거절정확도, 환각률	(실험 후 작성)

3.7 평가문항과 Gold Standard

평가문항은 파일럿 20문항과 Hold-out 본실험 80문항으로 구성한다. 파일럿 문항은 청킹, top-k, reranker, prompt 및 시스템 기능을 점검하는 데 사용한다. Hold-out 문항과 Gold answer는 설정조정과 모델선택에 사용하지 않으며, 파일럿 동결 이후 처음 실행한다. 두 집합 사이에는 동일 질문과 사실상 동일한 문항 template이 중복되지 않도록 검토한다.

Gold Standard는 정답 조문, 최소 충분 근거, 적용 version, 상·하위 또는 참조근거, forbidden_version, 모범답안, answerability 및 판정기준으로 구성한다. 항공운항·항공법규 전문가 3명이 독립평가하며, 문항 적합성의 중앙값 4 이상과 IQR 1 이하를 원칙으로 한다. 합의되지 않은 문항은 수정 또는 제외하고 그 과정을 기록한다.

전문가 수, 전문분야, 평가기간, 제외·수정 문항 수, 중앙값·IQR 분포 및 최종 100문항 구성을 기재한다 (실험 후에 작성 필요)

3.8 평가지표와 측정 방법

검색단계에서는 정답 근거가 top-k에 포함되는지를 나타내는 Hit@K, 최초 정답근거의 순위를 반영하는 MRR, 정답근거의 관련도와 순위를 함께 반영하는 nDCG@K를 계산한다. 정답근거가 여러 개 필요한 질문에는 최소 충분 근거집합을 기준으로 부분충족과 완전충족을 구분한다.

시간단계에서는 정답 version 선택 여부를 나타내는 Version Accuracy, forbidden_version 노출 및 질문일 기준 유효성 충족률을 측정한다.

다. 생성단계에서는 전문가 블라인드 평가로 답변정확성, 시간정합성, 근거충실성, 인용정확성, 인용완전성, 환각 및 답변거절의 적절성을 평가한다. 운영효율은 end-to-end 응답시간, retrieval·reranking·generation 단계별 시간, 입력·출력 token, 질문당 비용, index 구축시간 및 저장용량으로 비교한다.

3.9 통계분석 및 오류분석

동일 질문이 네 시스템에서 반복 측정되는 paired design을 적용한다. 이분형 지표는 전체 시스템 비교에 Cochran Q 검정을 사용하고, 사후 비교에는 paired proportion에 적합한 검정과 Holm 보정을 적용한다. 연속·서열 지표는 정규성 및 구형성 등 가정을 확인한 후 반복측정 ANOVA 또는 Friedman 검정 중 적합한 방법을 선택한다. 최종 논문에는 실제 사용한 검정만 보고하며, p-value와 함께 효과크기 및 95% 신뢰구간을 제시한다(Holm, 1979).

자료분포 검토 결과, 최종 통계검정, 다중비교 보정, 효과크기 산식, bootstrap 횟수 및 유의수준을 기재한다 (실험 후에 작성 필요)

오류는 retrieval, temporal, graph/relation, generation, citation 및 unanswerable-control 단계로 분류한다. 정답근거가 top-k에 없으면 검색 오류, 정답 component가 있으나 잘못된 version을 선택하면 시간오류, 필요한 상·하위·별표·위임근거를 확장하지 못하면 관계오류, 충분한 근거가 제공되었지만 결론을 잘못 생성하면 생성 오류로 코딩한다. 하나의 답변에 여러 오류가 연쇄적으로 나타날 경우 최초 발생단계와 최종 관찰오류를 각각 기록한다.

Table 8 Software and Experimental Environment

구분	사용항목	버전 및 설정
운영체제	OS 및 build	(실험 후에 작성 필요)
언어	Python	(실험 후에 작성 필요)
데이터 처리	pandas, pyarrow, lxml 등	(실험 후에 작성 필요)
RAG framework	LangChain 또는 LlamaIndex 실제 사용항목	(실험 후에 작성 필요)
Embedding	transformers, sentence-transformers, 모델 revision	(실험 후에 작성 필요)
Vector index	FAISS, PGVector 또는 실제 구성	(실험 후에 작성 필요)
Graph database	Neo4j 및 driver	(실험 후에 작성 필요)
데이터베이스	DuckDB 및 extension	(실험 후에 작성 필요)
생성모델	정확한 model ID와 access date	(실험 후에 작성 필요)
통계	scipy, statsmodels 등	(실험 후에 작성 필요)
하드웨어	CPU, RAM, GPU, VRAM	(실험 후에 작성 필요)
재현성	seed, config hash, code commit	(실험 후에 작성 필요)

3.10 소프트웨어 DB 및 실행 환경

재현성을 위해 운영체제, Python, 데이터 처리 라이브러리, 임베딩·RAG 프레임워크, vector index, graph database, 생성모델, 통계 패키지 및 하드웨어를 정확한 버전으로 기록한다. 버전은 논문 작성자의 기억이 아니라 실행환경에서 추출한 package lock, pip freeze, 시스템 manifest 및 DB metadata를 근거로 확정한다.

DuckDB 1.5.5의 정본 파일 Aviation_Law_Data.duckdb를 corpus registry, source_documents, norms, components, cleaned_components, supplementary, cleaned_appendices, provision_versions, temporal validation, operations requirements, amendment actions·edges, text_units, chunk_candidates, TT별 QA와 change log의 통합 저장소로 사용하였다. Google Drive에서 확인한 현재 DB 파일 크기는 2,544,906,240 bytes이다. Vector 검색은 DuckDB extension이 아니라 Milvus Lite에서 수행하도록 설계했으며, DuckDB에는 원문·구조·시간·청킹 metadata와 실험 추적정보를 저장한다. 최종 실험 동결본의 SHA-256은 해당 시점의 freeze manifest와 함께 확정·보고한다(실험 후에 작성 필요).

TT20에서는 chunks 테이블을 chunk_candidates로 명확히 변경하고 공식 view v_chunk_candidates_for_tt21, index idx_chunk_candidates_strategy 및 idx_chunk_candidates_text_unit을 생성하였다. 후보 교체, QA 갱신과 audit 삽입은 하나의

transaction으로 처리하였다. DuckDB의 ALTER RENAME 직후 이전 index binding이 남는 문제는 rename commit 후 connection을 다시 열어 해결했으며, 대량 삽입에는 PyArrow bulk transfer를 적용하였다.

IV 연구결과

4.1 데이터 구축결과

(제시 형식: 법령·기준별 수집량과 전처리 결과는 표로 제시하고, 문서유형별 조항 구성비는 누적 막대그래프로 제시한다.)

데이터 구축 결과, Raw V1은 총 99개 파일 (95 XML, 4 PDF)로 확정되었고 전수 무결성 QA를 통과하였다. Parser는 4개 norm, 93개 semantic document version과 239,509개 component를 생성하였다. 본문 정제 후 component 수는 239,509개로 동일하여 행 손실은 없었다. 시간·버전 구조화에서는 212,970개 provision version을 생성했으며 interval 및 현재본 중복 오류는 0건이었다. 법적 범위와 검색 가능성을 적용한 최종 검색 corpus는 57,672개 text unit과 875개 법적 관계로 구성되며, 이 중 청킹 비교에 투입되는 CONTENT Text Unit은 20,957개(법령 본문 6,822개, 구조화 운항요건 14,135개)이다.

TT11부터 TT19까지 모든 주요 실행은 고정 seed 표본검사와 idempotency 재실행을 통과하였다. TT17은 연속 version pair 196,293개를 비교해 변경 6,058개, 비변경 190,235개 및 diff

Table 9 Comparison of Candidate Chunking Strategies for TT21

후보	청크 수	중양길이	경계보존율	Hit@5	MRR	처리시간
Fixed 512 token						
Fixed 512 + overlap 50						
Fixed character 2,000						
Recursive paragraph-sentence						
Structural component						
Structural article-paragraph						
Appendix 18 row						
Appendix 36/technical						

Table 10 Generated-Answer and Citation Quality

지표	A	B	C	D	통계검정
답변정확성					
근거충실성					
시간정합성					
인용정확성					
인용완전성					
환각률					
거절정확도					

Table 11 Retrieval Performance on the Holdout Test Set

지표	A (Current)	B (All version)	C (Temporal)	D (SAT Graph)	통계검정
Hit@5					
MRR					
nDCG@5					

완전근거 회수율

span 26,431개를 생성하였다. TT18은 6,058개 amendment action과 18,174개 directed edge를 구성하고 756개 검토대상을 수동 판정하여 review_required를 0건으로 종료하였다. TT19에는 과거 첨부파일 6건의 coverage gap이 남아 있으나 차단오류가 아니라 명시적 한계로 기록하였다.

4.2 TT21 청킹 비교 결과

(제시 형식: 후보별 정확한 지표값은 표로 제시하고, 청크 길이분포는 box plot, Hit@5와 MRR은 군집 막대그래프로 제시한다.)

TT20에서는 동결된 20,957개 CONTENT Text Unit에 8개 후보전략을 적용하여 총 134,514개 chunk candidate를 생성하였다. 전략별 청크 수

는 fixed_512 20,966개, fixed_512_overlap50

20,966개, fixed_char_lbrag 20,957개, recursive_paragraph_sentence 20,966개, structural_component 20,957개, structural_article_paragraph 15,567개, appendix18_row 1,594개 및 appendix36_technical 12,541개였다. 전체 blocking QA issue는 0건이고 idempotency replay도 통과하였다. TT20 dataset digest는 5e466ce2466fc3efe5944582e262b082b0353b528025a5a17d502ca81ea926a9이다.

초기 regex 기반 token proxy가 한국어를 과소계수한 문제를 발견하여 BGE-M3의 실제 subword tokenizer로 교체하였다. 실제 token 진단 결과 CONTENT Text Unit의 중양값은 34 token, 평균은 43.28 token, P95는 106 token, 최대값은 562 token이었고 512 token을 초과한 unit은 9개(0.043%)뿐이었다. 따라서 여러 전략의 청크 수가 유사한 주된 원인은 fallback 오류

Table 12 Temporal Consistency Results

지표	A	B	C	D	주요 비교
Version Accuracy					
Forbidden version 노출률					
시간정합성					
미시행 오답률					

Table 13 Operational Efficiency Results

지표	A	B	C	D
평균 latency				
P95 latency				
입력 token				
출력 token				
질문당 비용				
index 구축시간				
저장용량				

가 아니라 원 corpus의 검색단위가 전반적으로 짧기 때문이었다. 실제 tokenizer 적용 후 token 기반 세 전략은 각각 20,966개로 증가했으며, structural_article_paragraph 후보를 추가해 단순 leaf 단위와 조·항 결합단위를 별도로 비교할 수 있게 하였다.

TT21에서는 승인된 20개 질문을 사용하여 동일 embedding, similarity와 top-k 조건에서 8개 후보의 Hit@K, Recall@K, MRR 및 nDCG@K를 비교한다. Gold Text Unit과 retrieved chunk의 source_text_unit_ids 교집합을 1차 관련성 기준으로 하고 component ID를 2차 구조검증에 사용한다. 현재 TT21 input contract와 질문파일은 준비되었으나 retrieval 비교와 최종

chunks_final 동결은 아직 수행되지 않았다. (TT21 실험 후 최종 전략·검색성능·동결 digest 작성 필요)

4.3 파일럿 20 문항 결과와 설정 동결

(제시 형식: 변경 전후 설정과 성능은 표로 제시하고, 오류유형 변화는 누적 막대그래프로 제시한다.) 파일럿 문항의 유형별 구성과 네 시스템의 초기 검색·생성 성능을 보고한다 (실험 후에 작성 필요) 발견된 오류와 수정한 청킹, top-k, reranker, prompt 또는 graph rule을 변경 전후

로 비교한다 (실험 후에 작성 필요)

파일럿 종료 후 동결한 config·prompt·Gold Standard·평가기준의 version과 hash를 보고한다 (실험 후에 작성 필요)

파일럿 결과는 시스템 조정과 기능 검증에 사용되므로 Hold-out 80문항의 최종 성능값과 합산하지 않는다.

4.4 Hold out 검색성능

제시 형식: 시스템별 Hit@5, MRR, nDCG@5와 통계검정은 표로 제시하고, 95% 신뢰구간을 포함한 점-구간 그래프로 시스템 차이를 제시한다.

80개 Hold-out 문항에서 시스템별 Hit@5, MRR, nDCG@5의 평균·중앙값·95% 신뢰구간을 보고한다 (실험 후에 작성 필요)

전체 비교검정, 사후 paired 비교, Holm 보정 p-value 및 효과크기를 보고한다 (실험 후에 작성 필요)

현행·과거·개정비교·다중근거·수치·미시행·답변불가 유형별 검색성능을 제시한다 (실험 후에 작성 필요)

4.5 버전 정확도와 시간 정합성

제시 형식: Version Accuracy와 forbidden-version 노출률은 표로 제시하고, 질문유형별 시간정합성

Table 14 Summary of Hypothesis Testing Results

가설	핵심비교	관측결과	통계 및 효과크기	판정
H1				
H2				
H3				
H4				
H5				

Table 15 Error Distribution by RAG System

오류유형	A	B	C	D	대표 원인
검색오류					
시간오류					
관계오류					
생성오류					
인용오류					
답변거절 오류					

은 군집 막대그래프로 제시한다.

System B와 C·D의 Version Accuracy, forbidden-version 노출률 및 유효성 충족률을 비교한다 (실험 후에 작성 필요)

과거·개정비교·미시행 문항에서 시간필터의 순효과를 절대차, 상대 오류감소율, 효과크기와 함께 해석한다 (실험 후에 작성 필요)

시간필터 이후에도 발생한 오류를 부칙, 경과 조치, query date 추출 및 metadata 품질로 구분한다 (실험 후에 작성 필요)

제시 형식: 오류 빈도와 대표 원인은 표로 제시하고, 최초 발생단계에서 최종 관찰오류로 이어지는 경로는 Sankey diagram으로 제시한다.

검색·시간·관계·생성·인용·답변거절 오류의 빈도와 비율을 시스템별로 보고한다 (실험 후에 작성 필요)

최초 발생단계와 최종 관찰오류를 구분하여 오류 전과경로를 분석한다 (실험 후에 작성 필요)

각 시스템의 대표 성공사례와 실패사례를 질문, 검색근거, 생성답변, Gold answer 및 판정사유와 함께 제시한다 (실험 후에 작성 필요)

4.6 답변 및 인용품질

제시 형식: 평가점수와 신뢰도는 표로 제시하고, 시스템별 품질지표 프로파일은 레이더차트 또는 군집 막대그래프로 제시한다.

답변정확성, 근거충실성, 시간정합성, 인용정확성, 인용완전성, 환각률 및 답변거절 정확도를

시스템별로 보고한다 (실험 후에 작성 필요)

평가자 간 신뢰도, 불일치 조정건수와 최종판정 절차를 보고한다 (실험 후에 작성 필요)

검색근거가 존재했음에도 생성이 실패한 사례와 검색단계 실패가 생성오류로 이어진 사례를 분리한다 (실험 후에 작성 필요)

4.7 오류분석

4.8 응답시간 토큰비용 및 저장자원

제시 형식: 정확한 운영효율 값은 표로 제시하고, 정확도-응답시간 및 정확도-비용의 trade-off는 산점도로 제시한다.

시스템별 end-to-end 및 단계별 평균·중앙값·P95 응답시간을 보고한다 (실험 후에 작성 필요)

입력·출력 token, 질문당 비용, index 구축시간, graph 구축시간, DB 및 index 용량을 비교한다 (실험 후에 작성 필요)

정확도 1%p 향상당 추가시간 또는 추가비용을 계산하고 사전 정의한 실무 허용기준 충족 여부를 판단한다 (실험 후에 작성 필요)

4.9 가설검정 결과

제시 형식: 가설별 핵심 비교, 효과크기, 보정 p -value 및 판정은 요약표로 제시한다.

H1부터 H5까지 핵심 비교, 통계량, 보정 p -value, 효과크기 및 지지 여부를 표로 정리한다 (실험 후에 작성 필요)

authority allocation을 검증할 필요가 있다. 또한 질문 유형에 따라 경량 vector 경로와 graph 경로를 선택하는 adaptive routing을 적용하여 정확도, 처리시간 및 비용효과 간의 균형을 분석할 필요가 있다. 실험 완료 후에는 실제 표본과 측정결과를 바탕으로 외적 타당도, 모델 종속성 및 운영비용에 관한 한계를 추가로 구체화해야 한다

V 결론

5.1. 결론

5.2. 시사점

본 연구는 한국 항공안전법령을 대상으로 버전 인식과 법령구조 인식이 RAG 성능에 미치는 효과를 분리하여 검증하고, 검색과 생성 단계별로 금지 버전 검색 여부, 시간정합성, 인용완전성 및 오류발생단계를 측정함으로써 단일 평균 정확도를 넘어선 항공 규제 RAG 평가체계를 제시한다는 점에서 학술적 의의가 있다. 또한 질문, Gold Standard, 원문 provenance, config hash 및 실행 manifest를 연계하여 실험의 재현성과 결과의 감사가능성을 강화하였다. 다만 연구범위가 대한민국 고정익 항공운송사업자의 운항승무원 규정과 전문가가 작성한 100개 문항으로 한정되어 있어 다른 항공분야·관할권·실제 업무질문으로의 일반화에는 주의가 필요하며, embedding, reranker 및 생성모델의 선택에 따라 성능과 비용이 달라질 수 있다. 아울러 운영자별 승인문서의 비공개성 및 상이한 적용범위와 자동 관계추출의 오류 가능성을 고려할 때, 규제 RAG는 원문 확인과 deterministic validation을 기반으로 전문가의 최종 판단을 지원하는 형태로 활용되어야 한다. 향후에는 실제 규제 담당자와 운항전문가를 대상으로 한 task-based usability 평가, 법령 개정에 대응하는 incremental update, adversarial metadata에 대한 fail-safe, 운영자별 approval context를 반영한 Compliance Digital Twin 및 human - AI

References

- Butler, A.-R., & Butler, U. (2026). Legal RAG Bench: An end-to-end benchmark for legal RAG. arXiv:2603.01710. <https://arxiv.org/abs/2603.01710>
- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. Findings of ACL 2024, 2318 - 2335. <https://doi.org/10.18653/v1/2024.findings-acl.137>
- de Martim, H. (2025). An ontology-driven Graph RAG for legal norms: A hierarchical, temporal, and deterministic approach. Legal Knowledge and Information Systems. <https://doi.org/10.3233/FAIA251598>
- EASA. (2023). Artificial Intelligence Roadmap 2.0: A human-centric approach to AI in aviation. European Union Aviation Safety Agency.
- EASA. (2026). EASA Artificial Intelligence Concept Paper—Proposed Issue 3. European Union Aviation Safety Agency. <https://www.easa.europa.eu/en/document-library/general-publications/easa-artificial-intelligence-concept-paper-proposed-issue-3>
- Edge, D., Trinh, H., Cheng, N., et al. (2024). From local to global: A graph RAG approach to query-focused summarization. arXiv:2404.16130. <https://arxiv.org/abs/2404.16130>

7. FAA. (2026). Technical discipline: Artificial intelligence - machine learning. Federal Aviation Administration.
https://www.faa.gov/aircraft/air_cert/step/disciplines/artificial_intelligence
8. Gebru, T., Morgenstern, J., Vecchione, B., et al. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86 - 92.
<https://doi.org/10.1145/3458723>
9. Guha, N., Nyarko, J., Ho, D. E., et al. (2023). LegalBench: A collaboratively built benchmark for measuring legal reasoning in large language models. *Advances in Neural Information Processing Systems*, 36.
<https://arxiv.org/abs/2308.11462>
10. Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65 - 70.
11. Huwiler, D., Stockinger, K., & Fürst, J. (2025). VersionRAG: Version-aware retrieval-augmented generation for evolving documents. *arXiv:2510.08109*.
<https://arxiv.org/abs/2510.08109>
12. IATA. (2026, March 11). IATA advances AI initiatives to support air cargo operations. International Air Transport Association.
<https://www.iata.org/en/pressroom/2026-releases/2026-03-11-01/>
13. Iyengar, A., Tiselska, A., Samaraweera, D., & Liu, H. (2026). Building trust in the skies: A knowledge-grounded LLM-based framework for aviation safety. *arXiv:2604.13101*.
<https://arxiv.org/abs/2604.13101>
14. Lewis, P., Perez, E., Piktus, A., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459 - 9474.
15. Pipitone, N., & Alami, G. H. (2024). LegalBench-RAG: A benchmark for retrieval-augmented generation in the legal domain. *arXiv:2408.10343*
<https://arxiv.org/abs/2408.10343>
16. Sarthi, P., Abdullah, S., Tuli, A., et al. (2024). RAPTOR: Recursive abstractive processing for tree-organized retrieval. *arXiv:2401.18059*.
<https://arxiv.org/abs/2401.18059>
17. Saxena, A., Chakrabarti, S., & Talukdar, P. (2021). Question answering over temporal knowledge graphs. *Proceedings of ACL-IJCNLP 2021*, 6663 - 6676.
<https://doi.org/10.18653/v1/2021.acl-long.520>
18. Schlichting, M. R., Rasmussen, V., Alazze, H., et al. (2025). LeRAAT: LLM-enabled real-time aviation advisory tool. *arXiv:2503.16477*.
<https://arxiv.org/abs/2503.16477>
19. Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., et al. (2016). The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, 3, 160018.
<https://doi.org/10.1038/sdata.2016.18>
20. Jo, B. (2026). A Compliance-Preserving Retrieval System for Aircraft MRO Task Search. *EACL 2026 Industry Track*, 317 - 329.
21. Sharif Rohani, A., Clarke, S. S., & Das, A. (2026). A large language model - based method for improving decision-making in aviation. *Frontiers in Aerospace Engineering*, 5, 1808857.
22. Zheng, T., Shen, S., & Zeng, C. (2025). A Retrieval-Augmented Generation Method for Question Answering on Airworthiness Regulations. *Electronics*, 14(16), 3314.