

구조·시간·인식 그래프 RAG를 활용한 대한민국 항공안전법령 질의응답 신뢰성 검증 연구

A Validation Study of Structure-Aware Temporal Graph RAG for Reliable Question Answering over Korean Aviation Safety Regulations

원고 버전	V0.5 (내용 보완본)
반영 범위	TT01-TT28 완료, TT29-TT31 검토 중, TT32 수정 전 상태를 구분 반영
후속 결과 입력	TT33-TT40 결과표·그림·해석 슬롯 마련
작성 기준일	2026-09-19

ABSTRACT


This study develops a controlled testbed for validating structure-aware and version-aware retrieval-augmented generation over Korean aviation safety regulations applicable to flight crew of fixed-wing air transport operators. Four systems are compared in a staircase design: Current Vector RAG, All-Version Naive RAG, Temporal-Filtered Vector RAG, and SAT-Graph RAG. The completed pipeline covers source freezing, legal structure parsing, temporal versioning, amendment linking, text-unit construction, chunk selection, embedding, vector and graph databases, common retrieval, and a shared generation contract. The frozen raw corpus contains 99 files. The structured database contains 239,509 components and 212,970 provision versions. After a body-restoration correction, 61,239 text units were produced. A 20-question chunking pilot selected the structural article-paragraph strategy (15,654 chunks; Recall@5=0.570; MRR@10=0.583; Hit@10=0.800). System implementations A–C have completed development runs but remain under pre-freeze review; System D requires a graph-empty fallback correction before comparison with System C. [After TT33–TT40: insert the holdout results, confidence intervals, effect sizes, hypothesis decisions, and final conclusion.]

Key Words: aviation safety law; legal RAG; temporal knowledge graph; version-aware retrieval; regulatory technology

최종 초록 업데이트 위치

TT38의 최종 지표와 TT39의 해석이 확정되면 마지막 두 문장을 실제 수치와 결론으로 교체한다. 파일럿 runtime health 수치는 최종 성능으로 사용하지 않는다.

Reliability = relevance + temporal validity + legal structure + provenance



TT01-TT32 build the controlled testbed; TT33-TT40 freeze, execute, score, and report the holdout experiment.

Fig. 1. Overall research storyline and evidence flow / 전체 연구 서사와 근거 흐름

I. 서론

1.1 연구배경과 필요성

항공운항의 안전성과 적법성은 단일 규정의 확인만으로 확보되지 않는다. 항공운송사업자의 운항승무원 자격, 교육훈련, 최근비행경험, 항공신체검사, 승무시간과 비행근무시간, 피로관리, 운항통제, 비행계획, 연료, 기상, 접근·착륙 및 복행에 관한 의무는 항공안전법, 같은 법 시행규칙, 별표, 행정규칙 및 운항기술기준에 분산되어 있다. 실무자는 질문의 기준일에 유효한 조문을 찾는 동시에 상·하위 규정의 연결, 위임관계, 예외조건과 원문 출처를 함께 확인해야 한다.

의미적 유사성만 사용하는 검색은 현재 조문과 폐지·개정된 과거 조문을 함께 반환할 수 있다. 생성모델은 시간적으로 무효한 근거도 자연스럽게 확정적인 문장으로 재구성할 수 있으므로, 법령 질의응답의 신뢰성은 단순 관련성보다 넓게 정의되어야 한다. 본 연구는 신뢰성을 검색 관련성, 시간적 유효성, 법령구조의 완전성, 인용의 추적가능성과 답변거절의 적절성으로 분해한다.

RAG는 생성모델의 매개변수 지식과 외부 검색지식을 결합하지만(Lewis et al., 2020), 평면적 벡터 검색은 법률문서의 위계·상호참조·개정·폐지·시행일을 충분히 표현하지 못할 수 있다. VersionRAG는 변화하는 문서의 버전 인식을, SAT-Graph는 규범의 구성요소·시간버전·법적 행위를 명시적으로 모델링하는 접근을 제시하였다(Huwiler et al., 2025; de Martim, 2025). 그러나 대한민국 항공안전법령에서 시간필터와 구조 그래프의 효과를 동일 조건에서 분리한 정량 검증은 부족하다.

1.2 연구목적과 분석논리

본 연구의 목적은 대한민국 항공안전법령의 고정의 항공운송사업자 운항승무원 규정을 대상으로, 버전 인식과 법령구조 인식이 검색 및 생성 신뢰성에 미치는 효과를 분리하여 검증하는 것이다. 네 시스템은 기능을 단계적으로 추가하는 계단식 비교구조를 갖는다. System B와 C의 차이는 시간필터의 순효과를, System C와 D의 차이는 동일한 시간필터 위에서 구조·관계 확장의 추가효과를 나타낸다. 질문, 청킹, 임베딩, 재순위화, 생성모델과 프롬프트를 공통화하여 검색 아키텍처 이외의 변수를 최대한 통제한다.




Fig. 2. Staircase comparison design for Systems A-D / 시스템 A-D의 계단식 비교설계

1.3 연구문제와 가설

Table 1. Research Questions and Hypotheses / 연구문제와 가설

구분	내용
RQ1	항공안전법령의 구조적·시간적 특성은 일반 Vector RAG의 검색·답변 신뢰성에 어떤 오류를 유발하는가?
RQ2	System C는 System B보다 retrieval accuracy와 temporal consistency를 향상시키는가?
RQ3	System D는 System C보다 다중근거 회수, 인용완전성과 답변품질을 향상시키는가?
RQ4	계층·규정 간·승인의존·시간 복잡성이 증가할수록 시간·구조 인식 검색의 상대효과가 커지는가?
H1	시간필터를 사용하는 C와 D는 B보다 Version Accuracy가 높고 forbidden-version 노출률이 낮다.
H2	법령관계를 사용하는 D는 C보다 다중근거 Hit@K, nDCG@K와 인용완전성이 높다.
H3	D는 A-C보다 답변정확성이 높고 환각률이 낮다.
H4	D의 지연시간과 비용은 증가할 수 있으나 정확도 항상 대비 사전 정의된 허용범위 안에 있다.
H5	범용 SAT-Graph의 효과는 항공안전법령의 다층 구조와 기술요건 때문에 제한될 수 있다.

1.4 연구범위와 기여

연구범위는 비행기를 사용하는 국내·국제항공운송사업자의 운항규칙과 운항승무원 규정으로 한정한다. 객실승무원, 정비, 항공교통관제, 보안, 공항운영과 회전의 고유규정은 원칙적으로 제외한다. 포함 주제는 자격, 교육훈련, 최근비행경험, 항공신체검사, 승무시간·비행근무시간, 피로, 운항통제, 비행계획, 연료, 기상, 교체비행장, 접근, 착륙과 복행이다.

본 연구의 기여는 세 가지다. 첫째, corpus·시간필터·구조확장을 단계적으로 통제하여 시간효과와 구조효과를 분리한다. 둘째, 정답 version뿐 아니라 사용해서는 안 되는 forbidden version을 Gold에 포함하고 검색·시간·관계·생성·인용 오류를 구분한다. 셋째, 원문 hash, 데이터·config·code 상태, 질문·Gold와 실행 manifest를 연계하여 재현성과 감사가능성을 확보한다.

II. 이론적 배경 및 선행연구

2.1 RAG와 법률문서 검색

RAG는 외부 문서를 검색해 생성모델의 입력에 결합함으로써 최신 지식과 출처를 제공한다(Lewis et al., 2020). 그러나 검색기가 잘못된 법령구간을 반환하면 생성모델이 그 오류를 유창하게 증폭할 수 있다. 법률 RAG 평가는 종단간 정답률뿐 아니라 필요한 최소 법률구간을 회수했는지, 질문시점에 유효한 version을 선택했는지, 인용이 실제 주장을 지지하는지를 분리해 측정해야 한다(Pipitone & Alami, 2024; Butler & Butler, 2026).

2.2 버전 인식과 시간 지식그래프

법령의 시간정합성은 문서 작성일 비교가 아니라 공포일, 시행일, 일부조문 시행일, 경과조치와 version 승계관계를 함께 다루는 문제다. Temporal KGQA는 사실과 관계에 유효기간을 부여해 질문시점에 적합한 지식을 선택한다(Saxena et al., 2021). VersionRAG는 버전 문서의 인텍싱과 변경정보를 결합했으나, 법령은 규범적 효력과 위임·부칙을 포함하므로 별도의 조작화가 필요하다.

2.3 구조 인식 SAT-Graph

SAT-Graph는 Norm, Component, Temporal Version, Language Version과 법적 Action을 구분하고, 원문 pointer와 시간정계를 유지한 결정론적 탐색을 제안한다(de Martim, 2025). 본 연구는 대한민국 법령의 법률-시행규칙-별표-운항기술기준, 조-항-호-목, 위임과 이행, 개정 전후 관계를 이 개념에 대응시킨다. 그래프는 원문을 대체하는 지식원이 아니라 후보 범위를 확장하고 검증하는 계층으로 사용한다.

2.4 법률·항공분야 RAG 평가와 연구공백

LegalBench는 법적 추론을 세분화했고(Guha et al., 2023), LegalBench-RAG와 Legal RAG Bench는 근거구간 및 종단간 평가를 제안하였다. 항공분야 연구는 구조화 청킹·재순위화와 지식그래프의 잠재력을 제시했지만, 시간효과와 구조효과를 같은 corpus·질문·생성조건에서 분리한 근거는 제한적이다. 특히 안전중요 영역에서는 정답률뿐 아니라 근거부족을 올바르게 표시하는 거절정확도와 오류 전파경로가 필요하다.

Table 2. Key Prior Studies and Their Role / 주요 선행연구와 본 연구의 역할

연구	주요 기여	한계	본 연구 적용
Lewis et al. (2020)	외부 비매개 지식과 생성모델 결합	법령 시간·위계 미반영	4개 시스템 공통 RAG 골격
Edge et al. (2024)	그래프·커뮤니티 기반 검색	추출관계가 공식 규범관계와 다를 수 있음	일반 GraphRAG와 결정론적 SAT-Graph 구분
Huwiler et al. (2025)	버전문서 QA와 변경정보	기술문서 중심	B-C 비교와 Version Accuracy
de Martim (2025)	법률 위계·시간·action 모델	대규모 정량검증 제한	D 구현 후 C와 paired 비교
Pipitone & Alami (2024)	최소 충분 법률구간 평가	시간·다중규정 범위 제한	Gold evidence와 검색·생성 분리평가

III. 연구설계 및 방법

3.1 전체 연구절차와 단계별 동결

연구는 연구범위·문헌·평가기준 확정, 공식 원문 수집과 동결, 구조·시간·개정관계 구축, 검색단위·청킹·인텍스 구축, 네 시스템 구현, 평가자료 동결, 파일럿과 Holdout 실행, 통계·오류분석과 재현성 패키지 정리로 이어진다. TT01-TT32는 비교실험의 전제인 데이터와 시스템을 구축하고, TT33-TT40은 평가자료를 동결한 뒤 결과를 산출·해석·보고한다.

Table 3. Overall Research Procedure and Task Mapping / 전체 연구절차와 Task 매핑

단계	주요 작업	Task	동결·산출물
1	연구범위·분석틀·평가기준	TT01-TT05	Protocol, 법령범위, metric/rubric
2	공식 원문 수집·QA·동결	TT06-TT09	Raw V1, manifest,

단계	주요 작업	Task	동결·산출물
			checksum
3	구조·시간·개정 모델	TT10-TT18	Component, version, action, edge
4	Text Unit·청킹·인덱스	TT19-TT27	Frozen chunks, embedding, Milvus, Neo4j, retriever
5	공통 생성과 A-D 구현	TT28-TT32	Prompt/log, four systems, development validation
6	질문·Gold·평가도구 동결	TT33-TT36	100 candidates → 80 holdout, pilot freeze
7	Holdout 실행·분석·보고	TT37-TT40	Raw runs, metrics, discussion, reproducibility package

3.2 연구대상과 원문 corpus

국가법령정보센터와 국토교통부 공식 공개자료에서 99개 파일을 수집하였다. 구성은 항공안전법 23개 XML, 항공안전법 시행규칙 36개 XML, 운항승무원 자격심사 관련 행정규칙 8개 XML, 고정익항공기 운항기술기준 28개 XML과 현행 전문 PDF 1개, 시행규칙 별표 4·18·36 PDF 3개다. 항공안전법 시행령은 직접 적용 범위를 검토했으나 최종 corpus에 포함할 원문이 없었다. TT08에서 0-byte, XML syntax, 파일손상과 checksum mismatch를 전수 확인했으며 모두 0건이었다. 동일 내용의 current endpoint와 latest history 2쌍은 의도된 alias로 기록하고 TT09에서 FRZ-TT09-001로 동결하였다.

Table 4. Data Collection Scope / 데이터 수집범위

법령·기준	선별범위	수집량
항공안전법	운항승무원·운항규칙 관련 현행·연혁	23 XML
항공안전법 시행령	직접 적용범위 검토 후 대상 없음	0
항공안전법 시행규칙	자격·훈련·운항·근무시간 관련 현행·연혁	36 XML
시행규칙 별표 4·18·36	운항승무원·승무시간 관련 표와 세부행	3 PDF
운항승무원 자격심사 규정	자격심사·기량·최근경험 관련 현행·연혁	8 XML
고정익항공기 운항기술기준	국제항공운송사업자 운항·훈련·자격 기준	28 XML + 1 PDF

3.3 법령 구조화·정제·시간모델

TT10은 norm - document version - component - provision version - text unit - chunk의 구조와 안정적 ID 규칙을 확정했다. TT11 parser는 95개 XML을 4개 norm, 93개 semantic document version과 239,509개 component로 변환했다. 동일 입력을 두 번 파싱한 결과 dataset digest가 일치했고 instance collision은 0건이었다.

TT12와 TT13은 raw_text를 보존하면서 표시태그, 공백·줄바꿈, 제어문자와 Unicode NFKC만 정규화하였다. 239,509개 component의 행 손실은 0건이었고, 67,161개 행에 정규화가 적용되었으며 51,695개 행에서 NFKC 변화가 확인되었다. 의미손실과 법령 상호참조 QA 오류는 0건이었다. 부칙 912개 component는 3,634개 구조화 행으로, 별표 1,856개 component는 354,503개 구조보존 line으로 변환했으며 Cleaning Rules는 FRZ-TT13-001로 동결했다.

TT14와 TT15는 212,970개 provision version에 valid_from, valid_to, 상태와 전후 version을 부여하고 법적·시간적 경계를 검증하였다. CURRENT 4,770개, EXPIRED 203,831개, FUTURE_EFFECTIVE 1,704개, 그 밖의 시행경계·당일대체 상태 2,765개로 구성되며 invalid interval, component별 중복 CURRENT와 premature FUTURE는 모두 0건이었다. TT15의 23개 검증규칙은 PASS 22개와 PASS_WITH_NOTE 1개였고 FAIL은 없었다.

TT16은 별표 18 요건 1,567개와 운항요건 15,751개를 구조화했고, 법적 범위와 검색가능성 조건을 통과한 14,135개를 검색대상으로 확정하였다. Raw V1에 없는 과거 기술기준 첨부파일 6건은 임의 복원하지 않고 coverage gap으로 유지하였다. TT17은 법적으로 연속한 196,293개 version pair를 비교해 변경 6,058개와 비변경 190,235개를 식별하고 26,431개 diff span을 생성했다. TT18은 변경 6,058개를 amendment action으로 확정하고 TERMINATES·CREATES·SUPERSEDES 각 6,058개, 총 18,174개 edge를 만들었다. 756개 검토대상을 전수 판정하여 unresolved와 review_required를 0건으로 종료하였다.

Table 5. Dataset Construction Results through TT18 / TT18까지의 데이터 구축결과

구분	생성·수집	제외·오류	최종 상태
Raw 원문	99 파일	오류 0	FRZ-TT09-001
Semantic document version	95 physical XML	alias 2쌍 통합	93
계층 component	239,509	행 손실 0	239,509
Provision version	212,970	interval 오류 0	212,970
구조화 운항요건	15,751	범위 밖 1,610·gap 6	14,135 retrievable
Amendment action / edge	6,058 / 18,174	unresolved 0	FRZ-TT18-001

3.4 Text Unit과 청킹전략 선정

TT19는 법령본문과 구조화 요건뿐 아니라 개정행위, 시간·계층 metadata와 법적 관계를 공통 검색단위로 통합하였다. 부모 조문의 고유 본문 1,189개가 누락된 문제를 복구한 TT19-TEXTUNIT-v1.1의 최종 Text Unit은 61,239개다. CONTENT 22,146개, ACTION 6,058개, TEMPORAL_METADATA 10,014개, HIERARCHY_METADATA 22,146개, DELEGATION_RELATION 658개, IMPLEMENTATION_RELATION 217개로 구성된다. TT19 corpus는 FRZ-TT19-002로 동결되었다.

TT20 v2.2는 22,146개 CONTENT Text Unit에 8개 전략을 적용해 140,546개 후보를 생성했다. TT21은 승인된 Q001-Q020을 동일한 BGE-M3 임베딩과 검색조건으로 비교했다. structural_article_paragraph가 15,654개 청크로 가장 높은 Recall@5(0.570), MRR@10(0.583)과 Hit@10(0.800)을 기록해 FRZ-TT21-001로 동결되었다. 이 전략은 2위보다 Recall@5가 10.5%p 높고 일반 leaf 후보보다 청크 수가 약 29% 적었다. 다만 Q014의 상·하위법 동시회수와 Q017-Q020의 시점질문은 한계로 남아, 이후 시간필터와 관계확장의 필요성을 직접 제시하였다.

Table 6. TT21 Chunking Pilot Results / TT21 청킹 파일럿 결과

전략	청크 수	Recall@5	MRR@10	Hit@10	순위·결정
Structural article-paragraph	15,654	0.570	0.583	0.800	1 / 최종 동결
Fixed character LBRAG	22,146	0.465	0.505	0.750	2
Structural	22,146	0.465	0.505	0.750	3

전략	청크 수	Recall@5	MRR@10	Hit@10	순위 결정
component					
Fixed 512 token	22,155	0.465	0.505	0.750	4
Fixed 512 + overlap 50	22,155	0.465	0.505	0.750	5
Recursive paragraph-sentence	22,155	0.465	0.505	0.750	6
Appendix 36 technical	12,541	0.245	0.313	0.400	7
Appendix 18 row	1,594	0.050	0.031	0.100	8

주: 동일한 승인 Q001-Q020, 동일 임베딩·유사도 조건. 파일럿 결과는 청킹 선택용이며 Holdout 최종 성능과 합산하지 않는다.

3.5 임베딩·Vector DB·Graph DB

TT22는 BAAI/bge-m3(revision 5617a9f61b028005a4858fdac845db406aefb181)를 dense mode, 1024차원, L2 정규화 후 inner product, fp16으로 고정하였다. A100 GPU의 fp32·fp16 smoke test에서 NaN, Inf, all-zero가 없었고 fp16은 인코딩시간을 75.36%, peak GPU memory를 49.78% 줄였다. TT23은 동결된 15,654개 청크를 전수 인코딩하여 입력-출력 건수와 dimension을 확인했다.

TT24와 TT25는 Milvus Lite의 aviationLaw_chunks 컬렉션에 vector와 chunk_id, text_unit_id, norm_id, document_version_id, component_id, law_name, article_no, valid_from/to, source_id와 tag metadata를 함께 저장했다. 15,654개 행의 ID 매핑과 자연어 검색 self-check가 통과하였다. TT27은 query embedding, direct Top-5, candidate Top-20과 BAAI/bge-reranker-v2-m3(revision 953dc6f6f85a1b2dbfca4c34a2796e7dde08d41e) 재순위화를 공통 모듈로 구현했고 seed 청크 rank=1 self-check를 통과했다.

TT26은 TT19 본문복구를 반영해 Neo4j 그래프를 재구축했다. 노드 289,575개(Action 6,058, CTV 212,970, Norm 4, Component 10,451, TextUnit 60,092)와 edge 485,907개를 적재했다. dangling edge, version cycle과 invalid temporal edge는 0건이었다. 동일 relation의 시점 반복으로 인한 duplicate edge 856건, REVIEW_REQUIRED CTV 4,137건과 직접 HAS_TEXT가 없는 CTV 197,044건은 삭제·추정하지 않고 PASS_WITH_NOTE로 보존하여 System D의 탐색규칙에서 다루도록 했다.

Table 7. Retrieval Infrastructure Built in TT22-TT27 / TT22-TT27 검색 인프라

계층	설정	규모	검증
Embedding	BGE-M3, dim 1024, fp16	15,654 vectors	NaN/Inf/zero 0
Vector DB	Milvus Lite, IP	15,654 rows	count:ID mapping-search PASS
Reranker	bge-reranker-v2-m3	Top-20 → Top-5	seed rank=1 PASS
Graph DB nodes	Neo4j 5.26.0	289,575	dangling 0, cycle 0
Graph DB edges	7 relation types	485,907	duplicate 856 REVIEW_REQUIRED

3.6 공통 생성계약과 네 RAG 시스템

TT28은 A-D가 같은 provider, model, temperature, prompt와 JSON 출력계약을 사용하도록 generation module을 공통화했다. 시스템 ID는 prompt에 노출하지 않으며, 제공된 evidence만 사용하고 as_of_date에 유

효한 근거만 적용하도록 했다. evidence가 없으면 provider를 호출하지 않고 결정론적으로 abstain하며, 공급되지 않은 인용과 non-JSON 출력을 거부한다. 단위테스트, offline smoke와 gpt-4.1-mini-2025-04-14 live smoke가 통과했고 문항×시스템×run 단위 JSONL·Parquet 로그에 입력, 검색근거, prompt hash, 응답, token, latency와 오류를 저장한다.

Table 8. Configuration and Comparative Purpose of Systems A-D / 시스템 A-D 구성과 비교목적

시스템	검색 corpus	시간처리	구조·관계	비교목적
A Current Vector	기준일 현재 유효본	별도 시점필터 없음	없음	현행질문 기준선
B All-Version Naive	과거·현재·미시행 포함	없음	없음	버전 혼재 위험
C Temporal-Filtered	모든 version	valid_from ≤ date < valid_to	없음	시간필터 순효과
D SAT-Graph	C의 temporal seeds	C와 동일	seed + graph expansion union	구조·관계 추가효과

TT29-TT31은 Q001-Q020 개발 실행을 완료했으나 승인 Gold 소스고정, 입력검증 게이트, empty-answer 오류진단과 법률전문가 검토가 남아 동결 전 상태다. TT32의 최초 구현은 graph scope가 비면 유효한 System C seed evidence도 폐기하는 결함을 보였다. 연구설계상 D는 C에 구조확장을 더한 시스템이어야 하므로, graph expansion이 비어도 C seed를 보존하고 graph_fallback_used를 기록하도록 수정한 뒤 TT32만 재실행해야 한다. 이 교정 전 D run은 C-D 효과 비교에 사용할 수 없다.

3.7 평가문항·Gold Standard와 TT33-TT40 실행계획

평가자료는 개발용 Q001-Q020과 본실험 후보 Q021-Q120을 분리한다. TT33에서 100개 후보를 3인의 독립 전문가가 내용타당성, 난이도, 시간정보, required evidence, forbidden version과 답변가능성 기준으로 검토하고 정확히 80개 Holdout을 선정한다. TT34는 검색·시간·답변·인용 평가도구를 구현한다. TT35는 pilot과 holdout의 중복·누출을 차단하고 조건을 통제한다. TT36은 20문항 파일럿으로 설정을 동결하되 최종 성능과 합산하지 않는다. TT37은 동결된 80문항을 네 시스템에 paired design으로 실행한다. TT38은 metric·통계·오류분석, TT39는 Discussion, TT40은 최종 원고와 재현성 패키지를 완성한다.

Table 9. Planned Stratification of the 80-Question Holdout / 80문항 Holdout 층화계획

유형	핵심 추론부담	주요 지표	최종 문항 수
현행	실험 기준일 현재 적용규정	Hit@K, 답변정확성	[TT33 선정 수 입력]
과거	특정 과거일의 유효 version	Version Accuracy	[TT33 선정 수 입력]
개정비교	개정 전후 내용·시행시점	변경근거 완전성	[TT33 선정 수 입력]
다중근거	위임·상하위·별표 근거 결합	nDCG, 인용완전성	[TT33 선정 수 입력]
수치·한도	시간·횟수·기간 추출	수치정확성	[TT33 선정 수 입력]
미시행	공포되었으나 시행 전인 규정	시간정합성	[TT33 선정 수 입력]
답변불가	corpus 밖 사실 또는 근거부족	거절정확도, 환각률	[TT33 선정 수 입력]

TT33 완료 전 후보 분포를 결과로 해석하지 않는다. 정확히 80문항과 Gold hash가 동결된 뒤 TT37을 실행한다.

3.8 평가지표와 통계분석

Table 10. Evaluation Metrics / 평가지표

영역	지표	판정기준
검색	Hit@5, Hit@10, Recall@5, MRR@10, nDCG@10	Gold evidence의 포함·순위·관련도

영역	지표	판정기준
시간	Version Accuracy, forbidden-version violation	질문일에 유효한 version과 금지 version 노출
생성	답변정확성, 근거충실성, 시간정합성	Gold answer와 기준일에 대한 전문가 판정
인용	인용정확성, 인용완전성	주장지지와 required evidence 포함
안전	환각률, 거절정확도	비근거 주장과 답변불가 처리
효율	평균·P95 latency, token, 비용, 저장량	단계별 자원소비와 정확도-비용 trade-off

같은 질문을 네 시스템에 반복 투입하므로 paired 분석을 사용한다. 이진 결과는 Cochran Q와 사후 McNemar 검정, 순위·연속 지표는 분포에 따라 Friedman 또는 반복측정 모형과 paired 비교를 적용한다. 다중 비교는 Holm 방식으로 보정하고, p-value와 함께 효과크기와 95% 신뢰구간을 보고한다. 평가자 간 신뢰도와 불일치 조정건수도 별도로 제시한다(Holm, 1979).

3.9 재현성·감사추적

핵심정본은 Research_Master.xlsx, Aviation_Law_Data.duckdb, RAG_Config_Master.yaml, research_pipeline.py, Experiment_Run_Master.parquet/JSONL과 본 원고다. 원문·데이터·config·code·질문·Gold·prompt·run manifest의 hash와 freeze ID를 연결한다. 이전 run과 수정 전 산출물은 덮어쓰지 않고 superseded 상태로 보존한다. 이 구조는 데이터 변경, 시스템 변경과 평가자료 변경을 구분하며 결과를 원문까지 역추적할 수 있게 한다.

IV. 연구결과

4.1 TT01-TT28 완료 결과

TT01-TT28을 통해 연구범위와 평가규칙, Raw V1, 구조·시간·개정 데이터, 최종 Text Unit과 청킹, embedding, Milvus·Neo4j, 공통 검색과 생성계약을 구축하였다. Raw 99개 파일에서 239,509개 component와 212,970개 provision version을 생성했고, 본문복구 후 61,239개 Text Unit을 확정했다. 22,146개 CONTENT Text Unit의 8개 청킹 후보 가운데 structural_article_paragraph 15,654개를 선택했으며 전수 embedding과 Vector DB 적재를 완료했다. 그래프는 289,575개 node와 485,907개 edge로 재구축했다.

Table 11. Status of TT01-TT32 Reflected in the Manuscript / 원고에 반영한 TT01-TT32 상태

영역	Task	상태	논문 반영사항
연구·평가 프로토콜	TT01-TT05	완료	범위, 비교설계, metric:rubric 확정
원문 수집·동결	TT06-TT09	완료	99 files, FRZ-TT09-001
구조·시간·개정	TT10-TT18	완료	239,509 components; 212,970 versions; 6,058 actions
Text Unit·청킹	TT19-TT21	완료·동결	61,239 units; 15,654 final chunks
검색 인프라	TT22-TT27	기술 검증 완료	embedding, Milvus, Neo4j, common retrieval
공통 생성	TT28	live smoke PASS	동일 prompt·모델·로그 계약

영역	Task	상태	논문 반영사항
Systems A-C	TT29-TT31	검토 중	개발 실행 완료, freeze-법을 검토 전
System D	TT32	수정 필요	graph-empty fallback 교정 후 재실행

4.2 TT21 청킹 비교 결과

구조적 article-paragraph 결합은 일반 leaf 단위와 고정길이 후보보다 적은 청크로 더 높은 Gold evidence 회수율을 보였다. Q001에서는 복구한 부모문과 구조결합의 효과로 Gold 3개를 Top-5에서 모두 회수했다. 반면 Q014는 시행규칙 제121조를 회수했지만 상위법 제55조의 동시회수가 제한되었고, Q017-Q020은 모든 후보가 시점·미시행 질문의 Gold를 충분히 찾지 못했다. 이 결과는 청킹만으로 해결되지 않는 시간필터와 관계 확장의 필요성을 보여주며, 이후 B-C와 C-D 비교의 설계근거가 된다.

4.3 TT29-TT32 개발 실행의 상태와 제한

Q001-Q020 개발 실행은 각 시스템의 end-to-end 경로가 동작하는지 확인하기 위한 것이며 최종 법률 성능평가가 아니다. PASS에는 abstain이 포함되고, error는 공통 생성계약의 empty-answer 검증실패를 포함한다. 특히 D의 짧은 실행시간은 효율 우위가 아니라 graph scope 공백 8건에서 LLM을 호출하지 않았기 때문이다. 따라서 다음 표는 runtime health로만 해석한다.

Table 12. Development Runtime Health for TT29-TT32 (Not Final Performance) / TT29-TT32 개발 실행상태

시스템	PASS	그중 abstain	실질 답변	ERROR	판정
A	18	3	15	2	검토 중
B	11	6	5	9	검토 중
C	19	3	16	1	검토 중
D	18	14 (graph-empty 8)	4	2	교정 전·비교 불가

주: PASS + ERROR = 20. PASS는 실행상 정상 abstain을 포함한다. Gold 기반 정답성·Version Accuracy·인용품질 검토 전이므로 연구효과를 뜻하지 않는다.

4.4 TT33-TT40 결과 입력구조

다음 표와 문단은 TT33-TT40의 실험값을 나중에 추가해도 방법과 결과의 논리적 연결이 유지되도록 설계하였다. 모든 결과는 동결된 80문항과 동일 run manifest에서 산출하고, 파일럿 수치와 합산하지 않는다.

Table 13. Retrieval Performance on the 80-Question Holdout / Holdout 검색성능

지표	A	B	C	D	전체검정	사후비교·효과크기
Hit@5	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
Hit@10	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
Recall@5	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
MRR@10	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
nDCG@10	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
완전근거 회수율	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]

4.4 검색결과 서술 입력

TT37 raw run과 TT38 통계 결과에서 평균·중앙값·95% 신뢰구간, 전체검정, Holm 보정 paired 비교와 효과크기를 입력한다. B-C는 시간필터, C-D는 구조확장의 순효과로 해석한다.

Table 14. Temporal Consistency Results / 시간정합성 결과

지표	A	B	C	D	전체검정	사후비교·효과크기
Version Accuracy	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
Forbidden-version violation	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
시간정합성	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
미시행 오답률	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]

4.5 시간효과 서술 입력

과거·개정비교·미시행 문항에서 B 대비 C의 절대차, 상대 오류감소율과 효과크기를 보고한다. 남은 오류는 부칙·경과조치, query date 파싱, metadata 품질로 구분한다.

Table 15. Generated-Answer and Citation Quality / 답변·인용 품질

지표	A	B	C	D	전체검정	사후비교·효과크기
답변정확성	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
근거충실성	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
시간정합성	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
인용정확성	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
인용완전성	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
환각률	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]
거절정확도	[입력]	[입력]	[입력]	[입력]	[입력]	[입력]

4.6 답변·인용결과 서술 입력

평가자 간 신뢰도, 불일치 조정건수, 검색근거가 있으나 생성이 실패한 사례와 검색실패가 생성오류로 전파된 사례를 구분해 기술한다.

Table 16. Operational Efficiency / 운영효율

지표	A	B	C	D	전체검정	사후비교·효과크기
평균 latency	[입력]	[입력]	[입력]	[입력]	[해당 없음]	[입력]
P95 latency	[입력]	[입력]	[입력]	[입력]	[해당 없음]	[입력]
입력 token	[입력]	[입력]	[입력]	[입력]	[해당 없음]	[입력]
출력 token	[입력]	[입력]	[입력]	[입력]	[해당 없음]	[입력]
질문당 비용	[입력]	[입력]	[입력]	[입력]	[해당 없음]	[입력]
Index/graph 구축시간	[입력]	[입력]	[입력]	[입력]	[해당 없음]	[입력]
저장용량	[입력]	[입력]	[입력]	[입력]	[해당 없음]	[입력]

4.7 운영효율 서술 입력

정확도 1%p 향상당 추가시간·추가비용을 계산하고 사전 정의한 허용기준 충족 여부를 판단한다. graph-empty short-circuit는 효율 향상으로 계산하지 않는다.

Table 17. Error Distribution by RAG System / 시스템별 오류분포

오류유형	A	B	C	D	대표 원인
검색오류	[입력]	[입력]	[입력]	[입력]	[대표 원인 입력]

오류유형	A	B	C	D	대표 원인
시간오류	[입력]	[입력]	[입력]	[입력]	[대표 원인 입력]
관계오류	[입력]	[입력]	[입력]	[입력]	[대표 원인 입력]
생성오류	[입력]	[입력]	[입력]	[입력]	[대표 원인 입력]
인용오류	[입력]	[입력]	[입력]	[입력]	[대표 원인 입력]
답변거절 오류	[입력]	[입력]	[입력]	[입력]	[대표 원인 입력]

4.8 오류분석 입력

최초 발생단계와 최종 관찰오류를 분리한다. 대표 성공·실패사례는 질문, retrieved evidence, 생성답변, Gold answer와 판정사유를 함께 제시한다.

Table 18. Summary of Hypothesis Tests / 가설검정 요약

가설	핵심비교	관측결과	통계·효과크기	판정
H1	[핵심 비교 입력]	[관측결과 입력]	[통계·효과크기 입력]	[지지/기각/유보]
H2	[핵심 비교 입력]	[관측결과 입력]	[통계·효과크기 입력]	[지지/기각/유보]
H3	[핵심 비교 입력]	[관측결과 입력]	[통계·효과크기 입력]	[지지/기각/유보]
H4	[핵심 비교 입력]	[관측결과 입력]	[통계·효과크기 입력]	[지지/기각/유보]
H5	[핵심 비교 입력]	[관측결과 입력]	[통계·효과크기 입력]	[지지/기각/유보]

4.9 가설검정 결과 입력

H1-H5의 전체검정, 보정 p-value, 효과크기, 95% 신뢰구간과 판정을 Table 18과 일치시키고, 유의하지 않은 결과도 방향과 불확실성을 함께 보고한다.

V. 논의

5.1 완료된 구축결과의 의미

TT01-TT28은 법령 RAG의 성능비교가 성립하기 위한 데이터·시스템 통제조건을 확립했다. 특히 TT19의 부모본문 복구와 TT21의 청킹 비교는 데이터 전처리의 작은 누락이 검색평가 전체를 왜곡할 수 있음을 보여준다. 구조결합 청킹의 성능 향상과 시점질문의 공통 실패는 구조와 시간문제를 구분한 본 연구의 계단식 설계가 필요함을 뒷받침한다.

또한 TT32의 graph-empty 결함은 그래프가 엄격할수록 항상 안전하다는 단순 가정을 경계하게 한다. 구조확장은 유효한 시간필터 근거를 대체하거나 제거해서는 안 되며, 그래프가 추가 근거를 찾지 못한 경우 C의 seed를 보존하는 fail-safe가 필요하다. 이는 D의 구조효과를 검증하기 전에 구현 동등성과 fallback 규칙을 먼저 검증해야 한다는 방법론적 교훈이다.

5.2 TT33-TT40 결과 해석 프레임

주요 결과 해석

TT39에서 B-C의 시간효과, C-D의 구조효과, 질문유형별 이질성과 정확도-비용 trade-off를 순서대로 해석한다. 평균점수만으로 결론을 내리지 않고 forbidden-version, 환각, 거절정확도와 오류 전파경로를 함께 본다.

선행연구와의 비교

VersionRAG, SAT-Graph, LegalBench-RAG 및 항공규정 RAG와 비교하되 corpus·문항·평가지표 차이를 명시한다. 선행연구의 수치를 본 연구 결과처럼 재사용하지 않는다.

한계와 타당도

표본 구성, 전문가 수, 법령 범위, 과거 기술기준 첨부파일 6건의 coverage gap, 모델·reranker 의존성, Graph relation coverage와 외적 타당도를 실제 결과에 맞춰 구체화한다.

VI. 결론 및 시사점

6.1 현재 단계의 결론

본 연구는 대한민국 항공안전법령의 구조·시간·개정정보를 원문 provenance와 연결하고, Current Vector, All-Version Naive, Temporal-Filtered Vector와 SAT-Graph RAG를 통제된 조건에서 비교할 수 있는 실험 기반을 구축했다. 현재 확정할 수 있는 결과는 데이터·인프라 구축과 TT21 청킹 파일럿까지다. TT29-TT31의 개발 실행은 동결·법률검토 전이며, TT32는 graph-empty fallback 교정이 필요하다. 따라서 네 시스템의 우열과 가설 지지 여부는 TT33-TT40 완료 전에는 결론내리지 않는다.

6.2 최종 결론 입력 위치

최종 결론

TT38과 TT39 완료 후 다음 순서로 1-2개 문단을 작성한다: (1) B-C 시간필터 효과, (2) C-D 구조효과, (3) 답변·인용·안전 지표, (4) 비용·지연 trade-off, (5) 규제 실무 적용조건. Abstract의 마지막 문장과 H1-H5 판정을 함께 갱신한다.

Appendix A. TT01-TT40-원고 반영 매핑

Table A1. Traceability from Team Tasks to Manuscript Sections / Team Task-원고 추적표

Task	핵심 내용	반영 위치	상태
TT01-TT05	범위·SAT/VersionRAG·평가·법령범위	I-II, 3.1-3.2	완료
TT06-TT09	수집·QA·Raw V1 동결	3.2, 4.1	완료
TT10-TT13	Schema·parser·cleaning	3.3, Table 5	완료
TT14-TT18	시간·별표·diff·amendment	3.3, Table 5	완료
TT19-TT21	Text Unit·청킹·선정	3.4, 4.2, Table 6	완료·동결
TT22-TT28	Embedding·DB·retrieval·generation	3.5-3.6, Table 7	완료/기술검증
TT29-TT31	Systems A-C	3.6, 4.3, Table 12	검토 중
TT32	System D	3.6, 4.3	교정·재실행 필요
TT33	100문항·Gold·전문가 검토	3.7, Table 9	결과 입력 예정
TT34-TT36	평가도구·통제·파일럿 Freeze	3.7-3.8	결과 입력 예정
TT37	80문항 Holdout 본실험	4.4-4.9	결과 입력 예정
TT38	최종 metric·통계·오류분석	Tables 13-18	결과 입력 예정
TT39	Discussion	V	결과 입력 예정
TT40	최종 논문·재현성 패키지	VI·전체	결과 입력 예정

편집용 추적표. 학회 투고본에서 부록 허용 여부에 따라 유지하거나 내부 재현성 문서로 이동할 수 있다.

References

1. Butler, A.-R., & Butler, U. (2026). Legal RAG Bench: An end-to-end benchmark for legal RAG. arXiv:2603.01710.
2. Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. Findings of ACL 2024, 2318–2335.
3. de Martim, H. (2025). An ontology-driven Graph RAG for legal norms: A hierarchical, temporal, and deterministic approach. Legal Knowledge and Information Systems. <https://doi.org/10.3233/FAIA251598>
4. EASA. (2023). Artificial Intelligence Roadmap 2.0: A human-centric approach to AI in aviation. European Union Aviation Safety Agency.
5. EASA. (2026). EASA Artificial Intelligence Concept Paper—Proposed Issue 3. European Union Aviation Safety Agency.
6. Edge, D., Trinh, H., Cheng, N., et al. (2024). From local to global: A graph RAG approach to query-focused summarization. arXiv:2404.16130.
7. FAA. (2026). Technical discipline: Artificial intelligence—machine learning. Federal Aviation Administration.
8. Gebru, T., Morgenstern, J., Vecchione, B., et al. (2021). Datasheets for datasets. Communications of the ACM, 64(12), 86–92.
9. Guha, N., Nyarko, J., Ho, D. E., et al. (2023). LegalBench: A collaboratively built benchmark for measuring legal reasoning in large language models. Advances in Neural Information Processing Systems, 36.
10. Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65–70.
11. Huwiler, D., Stockinger, K., & Fürst, J. (2025). VersionRAG: Version-aware retrieval-augmented generation for evolving documents. arXiv:2510.08109.
12. IATA. (2026, March 11). IATA advances AI initiatives to support air cargo operations. International Air Transport Association.
13. Iyengar, A., Tiselska, A., Samaraweera, D., & Liu, H. (2026). Building trust in the skies: A knowledge-grounded LLM-based framework for aviation safety. arXiv:2604.13101.
14. Jo, B. (2026). A compliance-preserving retrieval system for aircraft MRO task search. EACL 2026 Industry Track, 317–329.
15. Lewis, P., Perez, E., Piktus, A., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 33, 9459–9474.
16. Pipitone, N., & Alami, G. H. (2024). LegalBench-RAG: A benchmark for retrieval-augmented generation in the legal domain. arXiv:2408.10343.
17. Sarthi, P., Abdullah, S., Tuli, A., et al. (2024). RAPTOR: Recursive abstractive processing for tree-organized retrieval. arXiv:2401.18059.
18. Saxena, A., Chakrabarti, S., & Talukdar, P. (2021). Question answering over temporal knowledge graphs. Proceedings of ACL-IJCNLP 2021, 6663–6676.
19. Schlichting, M. R., Rasmussen, V., Alazeh, H., et al. (2025). LeRAAT: LLM-enabled real-time aviation advisory tool. arXiv:2503.16477.
20. Sharif Rohani, A., Clarke, S. S., & Das, A. (2026). A large language model-based method for improving decision-making in aviation. Frontiers in Aerospace Engineering, 5, 1808857.
21. Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., et al. (2016). The FAIR Guiding Principles for scientific data management and stewardship. Scientific Data, 3, 160018.
22. Zheng, T., Shen, S., & Zeng, C. (2025). A retrieval-augmented generation method for question answering on airworthiness regulations. Electronics, 14(16), 3314.