

## 구조·시간·인식 그래프 RAG를 활용한 대한민국 항공안전법령 질의응답 신뢰성 검증 연구

### A Validation Study of Structure-Aware Temporal Graph RAG for Reliable Question Answering over Korean Aviation Safety Regulations

#### ABSTRACT

This study evaluates Structure-Aware Temporal Graph Retrieval-Augmented Generation (SAT-Graph RAG) for question answering over Korean aviation safety regulations governing flight crew members of fixed-wing air transport operators. Under controlled experimental conditions, four systems are compared: Current Vector RAG, All-Version Naive RAG, Temporal-Filtered Vector RAG, and SAT-Graph RAG. A 20-question pilot set is used for system configuration and error diagnosis, while an independently reviewed 80-question hold-out set is reserved for final evaluation. System performance is assessed separately in terms of retrieval accuracy, version accuracy, temporal consistency, evidence completeness, answer correctness, citation accuracy and completeness, hallucination, appropriate abstention, latency, token consumption, and cost. Errors are further traced to retrieval, temporal filtering, structural relation expansion, answer generation, or citation stages. The final abstract will report the principal numerical findings, confidence intervals, effect sizes, hypothesis-testing results, and conclusions after completion of the hold-out experiment.

**Key Words** : aviation safety law(항공안전법), retrieval-augmented generation(검색증강생성), legal RAG(법률 검색증강생성), temporal knowledge graph(시간적 지식그래프), version-aware retrieval(버전인식검색), regulatory technology(규제기술)

## I. 서 론

### 1.1. 연구배경과 필요성

항공안전법령은 항공기 운항의 위험을 예방하기 위하여 자격, 교육훈련, 최근비행경험, 항공 신체검사, 승무시간과 비행근무시간, 피로관리, 운항통제, 비행계획, 연료, 기상, 접근·착륙 및

복행 등 상호의존적인 요건을 규율한다. 그러나 이러한 요건은 하나의 법률에 완결적으로 수록되어 있지 않다. 항공안전법, 같은 법 시행령·시행규칙과 별표, 고정익항공기를 위한 운항기술기준, 운항증명과 운영기준, 사업자별 운항규정 등 서로 다른 규범층위와 문서에 분산되어 있다. 실제 질의에 답하려면 질문과 문헌상 유사한 조항만 찾는 것이 아니라, 상위법의 위임근거, 하위기준의 구체적 요건, 예외와 경과조치, 승인문서의 적용범위를 함께 확인해야 한다.

국내 선행연구는 이 체계가 이용자에게 일관되고 명료한 형태로 제공되지 못한다는 점을 반복하여 지적하였다. 항공안전기술원(2021)은 운

Received : 00. Apr. 2024. Revised : 00. Oct. 2024.

Accepted : 00. Dec. 2024

\* 이파일은 심사위원이 확인하는 파일로 저자 인적사항은 별도의 Title page 파일에 명기해주시고, 이 파일에는 기입하지 않습니다.

항기술기준이 미국 FAA 모델규정을 바탕으로 형성되어 ICAO 국제기준의 적시 반영이 어렵고, 일부 조항에는 고시 간 중복·충돌, 상위법령상 근거의 불확실성 및 처벌기준 누락이 존재한다고 분석하였다. 또한 공통규정과 사업유형별 규정의 배치가 명확하지 않아 규정 이용자에게 혼란을 유발할 수 있다고 보았다. 이는 항공안전법령의 문제가 단순한 문서량의 문제가 아니라 위계, 적용대상 및 조문 간 관계를 함께 복원해야 하는 구조적 문제임을 뜻한다.

개별 법령영역을 다룬 연구도 같은 방향의 문제를 확인하였다. Ahn, Heo, and Hwang(2021)은 항공중사자에 대한 처분내용이 지나치게 일률적이고 가중·감경 사유가 모호하여 행정작용의 공정성과 예측가능성이 저하될 수 있다고 지적하였다. Kim et al.(2023)은 운항규정 위반을 판단할 때 수백 개의 사업자 규정과 법령상 처분근거가 결합되므로, 위반내용과 범위를 구체화하지 않은 채 ‘운항규정 미준수’만으로 제재하는 것은 예측가능성을 해칠 수 있다고 보았다. Kim(2023)은 항공안전법 제57조 제1항에서도 행위주체, 업무의 시점, 처벌과 자격처분의 비례성 문제가 남아 있음을 제시하였다. 최근 just culture 연구 역시 국내법상 고의·중과실 판단기준과 책임판단 절차가 충분히 구체화·표준화되지 않았다고 평가하였다(Yoo, Hwang, & Park, 2026). 이 연구들은 다루는 쟁점은 다르지만, 적용 가능한 조문을 찾는 것과 그 조문의 구체적인 의미·범위·관계를 판단하는 것이 분리될 수 없다는 공통점을 갖는다.

항공안전법령의 두 번째 핵심 특성은 시간성이다. ICAO 표준 및 권고방식과 관련 기술기준은 국내법에 신속히 반영될 필요가 있지만, 법률, 시행규칙, 별표, 운항기술기준 및 승인문서는 서로 다른 절차와 시차로 개정된다. 공포일과 시행일이 다를 수 있고, 일부 조문에는 별도 시행일 또는 경과조치가 적용된다. 동일 조문번호 아래 과거와 현재의 내용이 공존하므로, 질문 기준일에 적용되는 법을 선택하지 못하면 문언상 매우 유사하지만 법적으로는 적용되지 않는 버전을 근거로 답할 수 있다. 따라서 항공법령 질의응답은 최신문서 검색이 아니라 특정 시

점의 유효한 규범상태를 재구성하는 문제이다.

## 1.2. 문제제기와 연구의 필요성

대규모 언어모델은 법령을 자연어로 설명하는데 유용하지만, 학습시점 이후의 개정내용을 알지 못하거나 서로 다른 시점의 문언을 혼합할 수 있고, 존재하지 않는 근거를 그럴듯하게 제시할 수 있다. 검색증강생성(RAG)은 외부 corpus에서 관련 문서를 회수하여 생성모델에 제공함으로써 이 한계를 보완한다(Lewis et al., 2020). 그러나 법률분야에서 RAG를 사용한다는 사실만으로 법적 정합성이 보장되지는 않는다. 법률문서는 정확한 조·항·호·목의 경계, 정의와 예외, 관할과 효력, 상·하위 위임관계를 보존해야 하며, 잘못 검색된 근거는 오히려 유창한 오답의 근거가 될 수 있다.

최근 법률 RAG 연구는 이 문제를 여러 방식으로 다루었다. Temporal 또는 version-aware RAG는 질문시점과 문서버전을 연결하였고(Cymbler, Guez, & Fabre, 2026; Huwiler, Stockinger, & Fürst, 2025; Wang et al., 2026), RuleRAG와 메타데이터 기반 RAG는 질문유형과 규칙·메타데이터를 검색에 반영하였다(Chen et al., 2024; Poliakov & Shvai, 2024). GraphRAG와 LegalGraphRAG는 문서 전체의 구조적 관계와 다단계 검증을 활용하였고(Edge et al., 2024; Chen et al., 2026), SAT-GraphRAG는 법률의 구조, 시간 및 개정행위를 명시적으로 모델링 하였다(de Martim, 2025). 항공분야에서도 정비매뉴얼과 무인항공기 규제문서를 대상으로 RAG의 활용 가능성이 보고되었다(Ha et al., 2026; Immordino et al., 2026).

그럼에도 기존 결과를 대한민국 항공안전법령에 그대로 일반화하기는 어렵다. 기존 연구의 corpus는 판례, 단일 기술문서, 정책문서 또는 구조가 비교적 명시된 법률자료가 중심이었다. 반면 국내 항공안전법령은 조문 연혁뿐 아니라 법률·시행규칙·별표·운항기술기준·승인문서의 다층구조, 암묵적 위임과 준용, 개정 시차, 표·별표, 사업자별 적용범위를 함께 처리해야 한다. Graph 또는 temporal architecture가 유용하더라

도, 원문 정제와 구조복원이 부정확하면 잘못된 관계와 유효기간을 더 체계적으로 전파할 수 있다. 따라서 특정 RAG가 우수하다고 가정하기보다 데이터 전처리와 청킹을 먼저 검증하고, 버전 혼합, 시간필터 및 구조·관계 탐색의 효과를 단계적으로 분리하여 측정할 필요가 있다.

법률 RAG의 평가연구도 본 연구의 필요성을 강화한다. 1)CanLegalRAGBench는 좋은 검색결과가 곧 좋은 생성답변으로 이어지지 않으며, 생성주장의 일부가 검색근거에 의해 지지되지 않을 수 있음을 보였다(Zhao et al., 2026). ClaimRAG-LAW는 답변 전체 점수가 개별 주장의 무근거·모순을 가릴 수 있으므로 claim 단위 검증이 필요하다고 지적하였다(Das, Abualhaija, & Bianculli, 2026). LRAGE는 corpus, 검색기, reranker, generator 및 rubric의 상호작용을 분리하지 않으면 성능원인을 찾기 어렵다고 보았다(Park et al., 2025). 그러므로 항공안전법령 RAG는 최종 정답률뿐 아니라 검색, 시간정합성, 필수근거 완전성, 인용과 생성의 각 단계를 별도로 평가해야 한다.

### 1.3 연구목적

본 연구의 목적은 대한민국 항공안전법령 중 고정의 항공운송사업자 운항승무원 관련 규정을 대상으로, 데이터 정제와 구조보존 청킹, 버전 인식 및 법령관계 인식이 검색·생성 성능에 미치는 영향을 실증적으로 비교하는 데 있다. 이를 위하여 동일한 원문, 평가문항, 생성모델 및 평가기준을 유지하면서 정보구조만 달리한 네 시스템을 구축한다. System A는 실험 기준일의 현행 유효본을 색인한 Current Vector RAG, System B는 모든 연혁 버전을 시간필터 없이 색인한 All-Version Naive RAG, System C는 질문 기준일의 유효구간을 적용한 Temporal Filterd Vector RAG, System D는 System C에

법령 위계, 상호참조, 위임, 개정·대체 및 승인의 존 관계 탐색을 추가한 SAT-Graph RAG이다.

A-B 비교는 현재 유효본만 제공하는 실무적 baseline과 all-version corpus의 차이를 확인하고, B-C 비교는 시간필터가 버전혼입을 얼마나 줄이는지 측정한다. C-D 비교는 동일한 시간조건 아래 구조·관계 탐색이 제공하는 추가효과를 추정한다. 이 비교는 ‘Graph RAG가 Vector RAG보다 우수한가’를 포괄적으로 묻기보다, 시간성과 구조성이 각각 어느 질문유형에서 어느 정도 기여하는지를 식별하기 위한 것이다.

### 1.4 연구문제 및 가설

RQ1 구조보존 전처리와 청킹은 항공안전법령의 조문·별표·상하위 근거를 검색 가능한 단위로 얼마나 충실하게 보존하는가?

RQ2 모든 연혁 버전을 혼합한 System B와 시간필터를 적용한 System C 사이에 검색성능, 버전정확성 및 답변의 시간정합성 차이가 존재하는가?

RQ3 SAT-Graph RAG인 System D는 Temporal -Filtered Vector RAG인 System C보다 다중근거 회수, 인용완전성 및 답변정확성을 향상시키는가?

RQ4 질문의 시간적·계층적·교차규정 복잡성과 데이터·관계 품질은 각 시스템의 성능차이에 어떠한 영향을 미치는가?

H1 System C는 System B보다 적용버전 정확성과 시간정합성이 높고, 비적용 버전의 검색·인용률이 낮을 것이다.

H2 System D는 System C보다 복수의 필수근거가 필요한 질문에서 근거 완전성이 높을 것이다.

H3 System D는 구조·관계 탐색으로 이점을 얻지만, 국내 항공안전법령의 불완전한 관계표현, 복수 시간기준, 승인문서 의존성 및 원천 데이터 오류 때문에 System C 대비 추가 성능향상은 제한적일 수 있다.

H3은 SAT-Graph의 실패를 전제하는 결론이 아니다. 선행연구가 경고한 그래프 스키마 설계 부담, 상류 데이터 오류의 구조적 전파, 도메인

1) 캐나다 판례법을 바탕으로 실제 법률 질의와 전문가 검증 답변으로 구성된 법률 RAG 평가 벤치마크 데이터셋이다. 검색 성능과 최종 생성 답변 간의 불일치를 측정하며, 생성된 주장의 8~29%가 검색된 근거 문서에 의해 지지되지 않는 환각 현상 등을 검증한다(Zhao et al., 2026).

적용문제 및 자동평가의 한계를 국내 항공법령에서 검증하는 경쟁가설이다. 따라서 System D가 C보다 유의하게 개선되면 구조인식의 효용이 지지되고, 개선폭이 작거나 오류와 비용이 증가하면 제한조건이 확인된다.

## II. 이론적 배경 및 선행연구

### 2.1 RAG의 기본구조와 법률정보 검색

RAG는 외부 지식원에서 질문과 관련된 문서를 검색하고, 검색결과를 생성모델의 맥락으로 제공하여 답변을 생성하는 구조이다(Lewis et al., 2020). 생성모델을 재학습하지 않고 corpus를 갱신할 수 있고 답변근거를 노출할 수 있다는 장점이 있지만, 그 성능은 corpus, 청킹, 임베딩, 검색기(retriever), reranker, prompt 및 generator가 연쇄적으로 결정한다. 검색단계에서 필요한 근거가 누락되면 생성모델은 이를 복구하기 어렵고, 반대로 관련성이 낮거나 상충하는 근거가 입력되면 모델은 그 오류를 설득력 있게 통합할 수 있다.

법률문서에서는 ‘관련성’의 의미가 일반문서보다 엄격하다. 답변을 뒷받침하는 최소 조문뿐 아니라 정의, 예외, 시행일, 관할, 위임근거 및 하위 세부기준이 필요할 수 있다. LegalBench는 법률추론이 다양한 과업으로 구성되므로 단일 점수로 평가하기 어렵다는 점을 보여 주었고(Guha et al., 2023), LegalBench-RAG는 광범위한 문서가 아니라 답변을 지지하는 최소한의 정확한 구간을 회수하는 능력을 측정해야 한다고 제안하였다(Pipitone & Alami, 2024). MultiHop-RAG는 여러 문서의 근거를 결합해야 하는 inference, comparison 및 temporal query에서 기본 RAG의 검색과 생성 모두가 취약함을 확인하였다(Tang & Yang, 2024). 이는 항공법령에서 top-k 문서 중 하나가 관련된다는 사실만으로 충분하지 않고, 필수근거집합 전체가 회수되었는지를 평가해야 함을 의미한다.

### 2.2 Corpus 정제, 청킹 및 검색전략

RAG의 성능은 검색모델 이전에 corpus의 품

질과 검색단위에 의해 제한된다. 법령 원문에서 조·항·호·목의 경계가 손상되거나 제목과 본문이 분리되고, 별표의 행·열 구조와 각주가 소실되면 embedding은 법적 문맥을 표현하기 어렵다. 지나치게 작은 청크는 예외와 조건을 분리하고, 지나치게 큰 청크는 관련 없는 내용과 여러 버전을 함께 포함시킨다. LegalBench-RAG는 chunking 방식에 따라 retrieval 결과가 크게 달라지고, 일반 목적 reranker가 전문 법률문서에서 일관되게 우수하지 않음을 보고하였다(Pipitone & Alami, 2024). PolicyBot도 법률·규제 corpus로 확장하려면 깊은 번호체계와 논리적 완결성을 보존하는 domain specific chunking이 필요하다고 제안하였다(Nagarajan, Kumar, & Santhiappan, 2025).

법률문서의 내부기능을 고려한 연구도 있다. Sha et al.(2026)은 인도 대법원 판결을 사실, 쟁점, 주장, 분석, 판결 등 rhetorical role에 따라 분할하고 role-aware filtering과 hybrid retrieval, reranking을 결합하였다. 다만 평가가 인도 대법원 영문판결과 자동 LLM 지표에 한정되어, 다른 법체계·문서유형에 일반화되거나 법률전문가가 추론오류를 포착하는지는 확인되지 않았다. 이 한계는 청킹전략을 다른 domain에서 그대로 이식하기보다 항공안전법령의 구조단위에 맞추어 후보전략을 비교해야 함을 시사한다.

규제문서에 관한 Chasandras(2025)는 전문 corpus에 맞춘 신경망 기반 검색기와 키워드-의미 검색 융합(lexical-dense fusion), 재정렬(reranking)이 일반 목적 모델보다 유리할 수 있음을 보였다. 그러나 사용한 RePASs 평가지표는 의무문구를 단순히 결합하는 표면적 전략에도 높은 점수를 줄 수 있어, 높은 자동점수가 실제 답변의 법적 완전성을 보장하지 않았다. 연구자는 semantically aware metric과 비영어권·관할별 규제 corpus의 필요성을 향후과제로 제시하였다. PolicyBot 역시 citation tracing과 다단계 검색의 장점을 제시했지만, statute의 중첩번호체계, 판례의 선례관계, 조약의 다언어 병렬조항 등 각 domain의 구조에 맞춘 재설계를 요구하였다(Nagarajan et al., 2025). 따라서 본 연구에서는 자동점수만 최적화하지 않고 원문단

위의 전문가 Gold evidence와 인용검증을 병행한다.

검색전략은 질문유형에 따라 달라질 수 있다. HyPA-RAG는 질문복잡도를 분류하여 top-k, dense·sparse·knowledge-graph 사용여부 등을 적응적으로 선택하였다(Kalra et al., 2024). 그러나 단일 평가자, 충분히 검증되지 않은 parameter mapping, 합성학습질문 및 지식그래프 구축품질의 한계를 인정하였다. Multi-Meta-RAG는 질문에서 추출한 metadata로 database를 먼저 필터링하여 multi-hop 검색을 개선했지만, domain과 질문형식별 prompt template, 추가 추론시간 및 정확한 metadata를 요구했고, 결과도 정답사실을 직접 제공한 경우에는 미치지 못했다(Poliakov & Shvai, 2024). CBR-RAG는 법률사례의 부분별 유사도를 결합하여 baseline을 개선했지만, 효과가 약 1.94%로 제한적이었고 domain expert의 질적 검증과 corpus-specific fine-tuning이 후속과제로 남았다(Wiratunga et al., 2024). 이 결과들은 복잡한 구조를 추가하는 것 자체보다 domain에 맞는 데이터와 검증이 중요하다는 근거가 된다.

## 2.3 법률RAG의 평가 한계와 신뢰성

법률RAG의 평가에는 세 가지 문제가 있다. 첫째, 타당한 근거가 하나만 존재하지 않을 수 있다. CANLEGALRAGBENCH는 전문가가 선택한 판례와 다른 문서를 검색해도 법적으로 타당한 답이 가능하고, temporal relevance와 판례의 선행가치까지 고려하지 않으면 자동relevance 판정이 불완전해진다고 보았다(Zhao et al., 2026). 둘째, 좋은 검색이 항상 충실한 생성으로 이어지지 않는다. 동 연구에서oracle 문서를 제공해도 생성답변은expert answer와 상당히 달랐고, 일부claim은 검색근거에 의해 지지되지 않았다. 셋째, 전문가 검증은 비용이 크고 미묘한 오류 때문에 오히려 생산성을 상쇄하는 ‘verification debt’를 만들 수 있다.

ClaimRAG-LAW는 이러한 문제를 답변 전체가 아니라claim 단위에서 다루었다. 317개의 전문가 검증QA와968개claim을 이용한 평가에서

retrieval과 generation의 domain-specific weakness가 기존 벤치마크에 충분히 포착되지 않았고, general-domain claim verifier의 contradiction detection도 법률문맥에서 불안정하였다(Das et al., 2026). 다만synthetic QA, 두 언어와 두 문서, 단일 법률전문가 검증이라는 한계로 인해 실제 법률질문의 다양성을 완전히 반영하지 못했다. 따라서 본 연구는claim-level grounding을 채택하되, 실제 항공법령 원문에 기초한 전문가 문항과 복수검토를 사용한다.

LRAGE는 corpus, 검색기, reranker, generator 및rubric을 모듈별로 평가하여 성능차이의 원인을 분리할 필요성을 강조하였다(Park et al., 2025). 특히 한국 변호사시험 실험에서 dense retriever가 BM25보다 낮은 성능을 보였고, off-the-shelf agentic RAG가 항상 성능을 개선하지 않았다. 연구자는 법률domain에 맞춘 retriever와 agent prompt·tool·reasoning framework의 적응이 필요하다고 해석하였다. 이는 본 연구가 최신 또는 복잡한architecture를 우월한 조건으로 간주하지 않고, 동일한 설정에서 하나의 독립변수만 추가해 비교해야 하는 직접적 근거이다.

LexRAG는1,013개의 다회차 법률상담과 17,228개의 후보 법조문을 제공하여 대화맥락이 검색과 생성에 미치는 영향을 평가하였다(Li et al., 2025). 그러나 중국어corpus 중심이며, 후속 대화자료가 개인정보·보안 제약 때문에 주로 전문가 주석으로 구성되어 실제 비표준적 상담대화의 다양성을 충분히 반영하지 못했다. 이 한계는benchmark의 규모와 자동화 여부보다 평가 질문이 실제 대상domain의 문서구조와 사용자 질문을 대표하는지가 중요함을 보여 준다.

## 2.4 시간 오점지와 버전 인식 RAG

법령과 같이 동일 식별자 아래 내용이 계속 개정되는 corpus에서는 현재 조문과 과거 조문이 높은 의미유사도를 가진다. 질문에 날짜가 포함되어도 vector retrieval은 그 날짜를 법적 유효기간 제약으로 해석하지 못할 수 있다. Cymbler et al.(2026)은 이러한 오류를temporal

misgrounding, 즉 과거 또는 미래의 버전이 필요한 질문에 현재 유효버전을 체계적으로 검색·인용하는 현상으로 정의하였다. 프랑스 세법 32,436개 조문버전과 209개 전문가 문항에서 current-only static RAG는 2.7%의 정확도에 그친 반면, version-aware end-to-end retrieval은 98.3%, oracle은 99.1%에 도달하였다. 특히 static 조건은 적용 가능한 버전을 0% 회수하였다. 이 결과는 시간필터가 부가 metadata가 아니라 법률검색의 필수조건임을 보여 준다.

그러나 이 결과에도 범위가 있다. Fiscal QA Pro는 프랑스 조세법과 단일 기준조문을 중심으로 구성되었고, 현재법 대체 외의 미래법 유출, 특정 개정 전후 비교 및 두 버전 동시비교는 충분히 평가되지 않았다. 연구자도 다른 civil-law jurisdiction의 복제와 해석적 질문의 확장을 후속과제로 제시하였다(Cymbler et al., 2026). 국내 항공법령은 하나의 조문버전 선택에 더하여 상위법과 운항기술기준, 부칙, 승인문서의 효력 관계를 결합해야 하므로 temporal filtering만으로 문제가 해결되는지 별도 검증이 필요하다.

VersionRAG는 evolving document QA를 content, version 및 change retrieval로 구분하고 문서·버전·내용·변경을 명시적으로 연결하였다(Huwiler et al., 2025). 이 연구는 generic retrieval이 domain의 version pattern을 유연히 학습하기를 기대하기보다 문서의 version·section·temporal marker를 architecture에 명시적으로 모델링해야 한다고 주장하였다. 다만 평가는 34개의 기술문서와 100개의 수작업 문항에 한정되었고, 법령과 같은 amendment structure의 일반화는 검증되지 않았다. 또한 연속시간, 달력시점과 release의 연결, pipeline error propagation 및 indexing·운영비용 문제가 남았다.

IA-RAG는 Allen의 interval algebra를 사용하여 before, overlap, containment 및 duration 등 시간관계를 명시적으로 추론하였다(Wang et al., 2026). 이는 단순 날짜일치보다 복합적인 시간질문에 적합하다. 하지만 시간표현 추출과 interval normalization의 품질에 의존하고, 모호하거나 noisy한 시간 표현에서 오류가 발생하며, causal

relation과 evolving event dynamics는 명시적으로 모델링하지 않았다. 법령에서 시행일, 공포일, 개정일, 경과조치 및 사실발생일을 혼동하면 interval reasoning 자체가 잘못된 입력을 정교하게 처리할 수 있으므로, 본 연구는 시간정보의 추출·정규화 정확성을 RAG 성능과 분리해 검증한다.

## 2.5 구조·규칙·그래프 기반 RAG

Vector RAG는 질문과 국소 청크의 유사도를 계산하는 데 강하지만, corpus 전체의 주제구조나 여러 문서에 걸친 관계를 직접 표현하지 않는다. Edge et al.(2024)의 GraphRAG는 entity graph와 hierarchical community summary를 구축해 corpus 전체에 대한 global sense making 질문에서 vector RAG보다 포괄성과 다양성이 높은 답변을 생성하였다. 그러나 평가는 약 100만 token 규모의 두 corpus와 global question에 집중되었고, fabrication rate, 다른 domain 및 local retrieval의 일반화가 충분히 검증되지 않았다. 연구자들은 embedding 기반 local retrieval과 community summary를 결합한 hybrid approach를 후속방향으로 제시하였다. 그러므로 GraphRAG의 global summary 성과를 특정 조문을 정확히 선택해야 하는 법률 retrieval 성과로 직접 해석할 수 없다.

RuleRAG는 지식그래프에서 추출한 규칙을 질문과 함께 제공하여 검색기와 생성기가 근거 관계를 따라가도록 하였고, RuleQA에서 큰 성능향상을 보고하였다(Chen et al., 2024). 그러나 벤치마크 자체가 규칙에 맞추어 구성되었고, 일반RAG 데이터셋에 맞춤규칙 없이 적용했을 때 gain은 제한적이었다. 이는 법률규칙의 존재보다 질문과 corpus에 적합한 규칙 정의·검증이 성능을 결정한다는 점을 보여 준다. 항공법령에서도 ‘상위법-위임-하위기준’, ‘개정-대체’, ‘준용’과 같은 관계를 일률적인 edge로 처리하지 않고 법적 의미와 적용조건을 확인해야 한다.

LegalGraphRAG는 사실, 법조문 및 법원칙을 계층적으로 조직하고 Researcher, Auditor, Adjudicator 역할을 분리하여 근거회수, 검증 및

판정을 수행하였다(Chen et al., 2026). 이 연구는 정답이 맞더라도 필요한 근거가 없는 ‘unsupported correctness’를 핵심 위험으로 제시하고 traceable correctness를 높였다. 다만 공개 사법판단 벤치마크와 텍스트 입력에 한정되었고, 다중양식 증거와 실제 법률업무에 대한 일반화는 후속과제로 남았다. 특히 판례판단을 위한 fact-rule-principle graph와 행정법령의 version-hierarchy-action graph는 구조가 다르므로, 그래프 온톨로지는 분야별로 설계되어야 한다.

de Martim(2025)의 SAT-Graph RAG는 본 연구와 가장 직접적으로 관련된다. 이 연구는 법률을 평면 텍스트가 아니라 추상적 법규범, 시점별 표현, 조문 구성요소 및 개정행위가 연결된 통시적 구조로 모델링하여 point-in-time retrieval, hierarchical impact analysis 및 provenance reconstruction을 지원하였다. 그러나 연구자 스스로 국가규모 적용에는 상당한 engineering과 governance가 필요하고, 잘못된 validity interval 또는 action metadata가 retrieval 오류를 체계적으로 전파한다고 지적하였다. 또한 정량 benchmark의 부재를 notable gap으로 규정하고 temporal precision·recall, action attribution, causal-chain completeness 및 user study를 후속평가로 제안하였다.

이 한계는 본 연구의 당위성을 직접 뒷받침한다. 국내 항공안전법령은 빠른 국제기준 반영 과정에서 조문배치와 위임근거가 변하고, 문서 유형마다 개정·시행정보의 표현형식이 다르다. 이러한 corpus에서 SAT-Graph의 효과는 ontology의 이론적 적합성만으로 판단할 수 없고, 실제 전처리·버전 정규화·관계추출 이후 temporal-filtered vector baseline과 비교해야 한다. 즉 본 연구는 SAT-Graph의 개념을 반복 제안하는 연구가 아니라, 선행연구가 요구한 annotated benchmark와 controlled comparison을 항공안전법령에 구현하는 연구이다.

## 2.6 항공분야 RAG 적용과 일반화의 한계

Ha et al.(2026)은 Cessna 172 정비매뉴얼을 페

이지 이미지로 색인하는 multimodal 검색기와 생성 파이프라인을 구축하여 정비사의 검색부담을 줄일 가능성을 제시하였다. 그러나 페이지별 독립 임베딩은 여러 페이지에 이어지는 절차를 연결하지 못했고, 동일 장비명이 흩어져 있을 때 관련없는 페이지를 검색하였다. 또한 그림 제목과 본문의 간접 참조, 장별로 반복되는 그림번호 및 매뉴얼 개정 시 재 임베딩 필요성이 한계로 지적되었다. 이는 항공문서에서 시각적 표현을 포함한다는 것만으로 구조가 해결되지 않으며, 연속절차와 고유식별자·교차참조를 전처리 단계에서 복원해야 함을 보여 준다.

Immordino et al.(2026)은 무인항공기 안전평가와 규제준수 보증을 위한 RAG assistant에서 권위 있는 원문을 sole source of truth로 두고, evidence-based answer, explicit citation, refusal 및 human assessor의 책임을 강조하였다. 실험 결과 source 용어와 질문표현이 일치할 때는 강했지만, paraphrase와 heavily reworked query에서는 recall이 낮아졌고, 올바른 문서가 검색되어도 생성문장이 가장 관련된 근거에 일관되게 귀속되지 않았다. 연구자는 이를 ‘retrieval quality is necessary but not sufficient’라고 요약하고, retrieval을 primary safety barrier로 취급해야 한다고 제안하였다.

동 연구는 GraphRAG가 복합 규제요건의 multi-step retrieval과 inspectable reasoning path에 유용할 수 있지만, schema design burden, extraction error의 구조적 전파 및 지속적인 graph governance가 위험이라고 보았다. 따라서 제한된 domain subset, 원문청크와의 엄격한 linkage, 인증전문가 validation loop를 거쳐 점진적으로 도입해야 한다고 제안하였다(Immordino et al., 2026). 이는 본 연구에서 System D를 chunk-based retrieval의 대체물이 아니라 System C에 추가되는 비교조건으로 설계하는 근거가 된다.

## 2.7 선행연구의 한계와 본 연구의 대응

선행연구를 종합하면 기술적 진보와 별개로 다섯 가지 공백이 남는다. 첫째, 국내 항공법 연

표 3 선행연구 한계 및 본 연구의 대응

| 선행연구에서 확인된 한계                                                  | 연구상 시사점                                      | 본 연구의 대응                                                             | 비교·평가지점                                            |
|----------------------------------------------------------------|----------------------------------------------|----------------------------------------------------------------------|----------------------------------------------------|
| 국내 항공법령의 중복·충돌, 위임근거 불확실성, 처분기준 모호성                            | 문언 유사도만으로 적용 규범을 확정할 수 없음                    | 조·항·호·목, 별표, 문서위계와 관계를 구조화하고 원문provenance 보존                         | 청킹 평가; evidence completeness; citation accuracy    |
| Static/current-only RAG의 temporal misgrounding                 | 질문일자의 적용버전 선택이 필수                            | 전체 연혁을 보존하되 component-level valid interval과 forbidden version 구축     | B-C; Version Accuracy; forbidden-version rate      |
| VersionRAG의 법률domain 일반화·연속시간·오류전파 한계                          | 시간metadata 추출품질을 별도 검증해야 함                   | 공포일·시행일·경과조치·개정행위 정규화 및QA                                            | temporal metadata audit; error attribution         |
| GraphRAG의 domain 제한 및 SAT-Graph의 정량 benchmark 부재               | 그래프 추가효과를 동일 baseline에서 검증해야 함               | C와 동일한 시간필터 위에 검증된 법령관계만 추가                                          | C-D; relation precision; multi-hop completeness    |
| Rule/metadata/adaptive RAG의 template·classifier·schema 의존성     | 복잡한 architecture의 효과는 domain adaptation에 좌우됨 | 관계 whitelist, hop/evidence budget, ablation 및 설정 동결                  | 오류유형별 성능; latency·cost                             |
| Answer-level·자동평가가 unsupported claim과 alternative evidence를 놓침 | 검색·생성·인용을 분리하고 전문가 검증 필요                     | claim-level grounding, alternative valid evidence, 전문가 Gold Standard | retrieval metric + claim/citation/human evaluation |
| 항공문서RAG의 페이지 단절, 교차참조 손실, paraphrase recall 저하                 | 항공문서 구조에 맞는 전처리와 보수적 생성 필요                   | 구조보존 청킹 비교, hybrid retrieval, evidence gap·abstention 평가             | RQ1; recall; refusal appropriateness               |

구는 규범의 중복·충돌·모호성과 제도개선 필요성을 확인했지만, 이 문제가 정보검색에서 어떤 오류로 나타나는지 정량화하지 않았다. 둘째, legal RAG benchmark는 retrieval과 generation의 취약성을 보여 주었지만 조문연혁과 forbidden version을 포함한 항공법령 benchmark는 없다. 셋째, temporal RAG는 버전선택의 중요성을 입증했지만 다층적 위임·준용·승인관계를 함께 평가하지 않았다. 넷째, graph·rule·metadata RAG는 구조의 가치를 제시했지만 domain-specific graph 품질과 baseline 통제가 충분하지 않았다. 다섯째, 항공RAG는 매뉴얼과 UAS 규제에서 가능성을 보였으나 대한민국 항공안전법령의 장기 연혁과 규범위계를 대상으로 하지 않았다.

이상의 분석에서 본 연구의 핵심 논리는 다음과 같이 정리된다. 항공안전법령은 구조와 시간의 복잡성이 동시에 존재하므로current-only 또는all-version vector retrieval만으로는 충분하지 않다. 그러나 구조와 시간을 명시적으로 모델링한SAT-Graph도 데이터 정제, validity interval 및 법령관계가 정확하지 않으면 큰 향상을 보장하지 못한다. 따라서 법령을 수집·정제하고 구조 보존 청킹의 성능을 먼저 평가한 뒤, A-B로

corpus 구성효과를, B-C로 시간필터효과를, C-D로 구조·관계 탐색의 추가효과를 분리해야 한다. 이 분석들은 제3장의 데이터 전처리, 청킹평가, 네 시스템 구축 및 단계별 성능비교로 이어진다.

### III 연구설계

#### 3.1 연구설계의 기본원칙

본 연구는 대한민국 항공안전법령 질의응답에서 시간 필터와 법령 구조 인식이 각각 어느 정도의 추가효과를 갖는지 분리하여 검증하는 통제 비교실험이다. 연구의 독립변수는 검색 코퍼스의 시간 범위와 구조·관계 탐색의 적용 여부이며, 종속변수는 검색 정확도, 시간정합성, 필수근거 완전성, 생성답변 정확성 및 효율성이다. 청킹, 임베딩, reranker, prompt, 생성모델, top-k와 근거 예산은 네 시스템에서 동일하게 고정한다. 이에 따라 A-B 비교는 모든 버전 혼합의 영향을, B-C 비교는 질문시점 필터의 순효과를, C-D 비교는 시간 필터 이후 구조·관계 탐색이 제공하는 추가효과를 측정한다.

실험 데이터는 원천파일에서 최종 검색 청크

표 4 연구 데이터의 범위와 원천자료 동결 기준

| 구분             | 포함자료                           | 단위/수량                         | 처리원칙                                        |
|----------------|--------------------------------|-------------------------------|---------------------------------------------|
| 법령 본문          | 항공안전법 및 시행규칙의 현행·연혁 XML        | 95 XML / 93 semantic versions | 물리적 source ID와 의미적 document-version ID를 분리  |
| 별표·서식          | 운항승무원 관련 별표 4, 9, 17, 18, 36 등 | 원문 XML/PDF                    | 표 구조·수치·단위·조건과 원문 위치를 보존                    |
| 행정규칙           | 고정의 운항기술기준과 관련 이력              | XML 및 공식 PDF                  | 공식 section code와 requirement label을 식별자로 사용 |
| 개정 근거          | 제·개정문, 부칙, 시행일·경과조치            | 문서버전별                         | 공포일과 시행일을 분리하고 원문 근거를 연결                    |
| Raw Dataset V1 | 수집·QA가 완료된 전체 원천파일             | 99 files: 95 XML + 4 PDF      | FRZ-TT09-001로 읽기 전용 동결                      |

## Data preparation and controlled RAG experiment pipeline




그림 1 데이터 전처리 및 통제 RAG 실험 파이프라인

까지 단계별 산출물을 별도로 보존하고, 각 단계에 QA gate와 SHA-256 기반 동결점을 둔다. 이러한 설계는 전처리 오류와 검색 아키텍처의 효과를 혼동하지 않도록 하며, 동일한 데이터와 설정으로 실험을 재현할 수 있게 한다. 그림 3-1은 자료수집부터 네 시스템 비교까지의 전체 흐름을 보여준다.

## 3.2 연구대상 및 데이터 수집

연구대상은 대한민국 고정의 항공운송사업자의 운항규칙 및 운항승무원 관련 규정으로 한정한다. 핵심 범위에는 항공안전법, 항공안전법 시행규칙, 관련 별표와 고정의항공기를 위한 운항기술기준이 포함된다. 세부 주제는 자격과 한정, 최근 비행경험, 항공신체검사, 교육훈련, 승무시간·비행근무시간·휴식 및 피로관리, 운항통제, 비행계획, 연료, 기상, 교체비행장, 접근·착륙 및 복행으로 구성한다. 회전익항공기, 객실승무원 또는 운항관리사만을 대상으로 하는 독립 규

정은 제외하되, 운항승무원 규정과 직접적인 위임·시행·승인 관계가 있는 경우 연결근거로 보존한다.

공식 원문은 국가법령정보센터와 국토교통부 공개자료에서 수집하였다. 현행본뿐 아니라 연혁본, 제·개정문, 부칙, 별표 및 운항기술기준 첨부자료를 포함하였다. 원천자료 동결본은 총 99개 파일로, XML 95개와 PDF 4개로 구성된다. 95개 물리적 XML 가운데 현행 endpoint와 최신 연혁 endpoint가 동일한 공식 판본을 가리키는 두 쌍은 의도된 alias로 처리하여 93개의 의미적 문서버전으로 통합하였다.

## 3.3 원천자료 품질검사와 동결

수집된 파일에는 0 byte 여부, 파일 열기 가능 여부, XML syntax, 필수 메타데이터, 파일 크기, SHA-256, 원천 URL 및 로컬 경로를 기록하였다. 99개 파일 전수검사에서 0 byte, 손상 및 XML syntax 오류는 발견되지 않았다. 동일

표 5 데이터 전처리 산출물과 품질검사 (Preprocessing outputs and QA gates)

| 단계                      | 주요 산출물                         | 수량           | 핵심 QA 게이트                                                  |
|-------------------------|--------------------------------|--------------|------------------------------------------------------------|
| Raw QA                  | 동결 원천파일                        | 99 files     | 0-byte·손상·syntax 오류 0; inventory digest 재현                 |
| Parsing                 | semantic versions / components | 93 / 239,509 | collision 0; 20-sample PASS; idempotency PASS              |
| Body cleaning           | cleaned components             | 239,509      | row loss 0; meaningful/legal-reference loss 0              |
| Supplementary           | supplementary rows             | 3,634        | 시행일·경과조치 원문 및 locator 보존                                   |
| Appendix cleaning       | structured appendix lines      | 354,503      | 수치·단위·조건 손실 0; 30-sample PASS                              |
| Temporal master         | provision versions             | 212,970      | invalid interval 0; multiple-current 0; 23-rule validation |
| Structured requirements | retrievable requirements       | 14,135       | out-of-scope retrievable 0; coverage gap 6건 명시             |
| Text units              | retrieval text units           | 61,239       | empty searchable text 0; source/version provenance 필수      |

hash를 가진 두 쌍은 중복삭제하지 않고 현행 endpoint와 최신 연혁 endpoint가 동일 판본을 제공한 provenance alias로 문서화하였다. QA를 통과한 원천자료는 FRZ-TT09-001로 동결하고 이후 단계에서 읽기 전용으로 사용하였다. 원문을 추가하거나 교체하는 경우 기존 동결본을 수정하지 않고 RAW-V2와 별도의 변경이력을 생성하도록 하였다.

원천 URL을 통한 전체 채수집은 당시 collector가 구현되지 않아 독립적으로 반복하지 못했으므로 이 항목은 PASS WITH NOTE로 기록하였다. 다만 동결 디렉터리와 QA manifest를 이용한 99개 파일 inventory 및 통합 digest는 독립적으로 재현하였다. 이 제한은 원천파일의 내부 무결성 검사를 부정하는 것이 아니라, 온라인 원천의 동일성 재검증 범위를 명확히 한 것이다.

### 3.4 법령 구조 모델링과 파싱

파서는 원천 XML을 법령(norm), 문서버전(document version), 구조요소(component), 조문버전(provision version)으로 분리하였다. 구조요소는 편·장·절·관·조·항·호·목·별표·서식 및 운항 기술기준 section으로 구분하였다. 각 요소는 문언이나 제목이 바뀌어도 동일한 법적 위치를 추적할 수 있도록 공식 법령 ID, 조문번호, 가지번호와 명시적 section label을 기반으로 결정론적 ID를 부여하였다. 반면 문구 자체는 식별자 생

성에서 제외하였다. 명시적 label이 없는 표의 행이나 기술기준 bullet은 cross-version stable identity를 임의로 부여하지 않고, 문서버전과 source locator에 종속된 instance ID로 관리하였다.

파싱 결과 95개 XML에서 93개 의미적 문서버전, 4개 norm, 239,509개 component를 생성하였다. parser QA는 25,654건이었으며, instance collision은 0건이었다. 원문-파싱 결과 20건 표본검토를 통과했고, 동일 입력을 두 차례 파싱했을 때 행수와 dataset digest가 일치하여 먹등성을 확인하였다.

### 3.5 데이터 정제와 구조 보존

정제의 목적은 검색에 불필요한 표현상의 변이를 줄이는 데 있으며 법률문언을 요약하거나 제작성하는 데 있지 않다. 일반 본문에는 HTML entity 해제, 표시 전용 tag 제거, Unicode NFKC, 줄바꿈 통일, 줄 내부 연속 공백 축약 및 빈 줄 제거를 적용하였다. 정제 전 raw\_text와 정제 후 cleaned\_text, 각각의 hash와 source locator를 함께 저장하였다. 조문 239,509건은 행 손실 없이 동일한 수의 cleaned component로 변환되었고, 67,161건에 정규화가 적용되었으며 이 가운데 51,695건은 NFKC 변환을 포함하였다.

법적 의미 손실을 막기 위해 “다만”, “에도 불구하고”, “제외한다”, “한정한다” 등의 제한표

표 6 청킹 후보와 생성 청크 수 (Chunking candidates and corpus size)

| 후보 전략                        | 핵심 단위                               | 청크 수   | 비고              |
|------------------------------|-------------------------------------|--------|-----------------|
| fixed_512                    | 512-token fixed window              | 22,155 | 고정길이 기준선        |
| fixed_512_overlap50          | 512-token, overlap 50               | 22,155 | 경계 단절 완화        |
| fixed_char_lbrag             | character-based fixed chunk         | 22,146 | 문자길이 기준 비교      |
| recursive_paragraph_sentence | paragraph-sentence recursive        | 22,155 | 문단·문장 경계 활용     |
| structural_component         | legal component                     | 22,146 | 조·항·호·목 단위      |
| structural_article_paragraph | article-paragraph hierarchy         | 15,654 | 상위 조문과 문단 맥락 결합 |
| appendix18_row               | Appendix 18 row                     | 1,594  | 승무·비행근무·휴식 표    |
| appendix36_technical         | Appendix 36 / technical requirement | 12,541 | 운항규정·기술기준 요건    |

현과 제○조·항·호·별표 인용이 사라지는 경우를 blocking error로 정의하였다. meaningful text가 비어버린 경우도 동일하게 실패 처리하였다. 전체 검사에서 의미 있는 본문 손실, 법적 제한표 현 손실 및 cross-reference 손실은 0건이었고, 원문과 정제문 20건 표본검토를 통과하였다.

부칙과 별표에는 별도의 구조보존 규칙을 적용하였다. 부칙은 시행일, 경과조치, 적용례, 준비행위, 폐지·관계조항을 독립 row로 분리하되 원문을 보존하였다. 912개 부칙 component에서 3,634개 supplementary row를 생성하였다. 별표는 표 전체를 하나의 평문으로 합치지 않고, 표 경계, 열 머리글, 병합표제, 단위행, 데이터행 후보를 유지하는 line-level record로 변환하였다. 1,856개 별표 component에서 354,503개 비어 있지 않은 구조화 line을 생성하였다. 수치·단위·조건·인용근거 손실 검사는 0건이었으며, 고정 seed 130013으로 추출한 30건의 raw-parsed-cleaned 대조를 모두 통과하였다.

### 3.6 시간·버전정보와 법률관계 구축

각 component의 문서판본별 내용을 provision version으로 구성하고 공포일, 시행일, 부칙, 다음 판본과의 관계를 이용하여 valid\_from과 valid\_to를 부여하였다. 특정 기준일 d에서 유효한 판본은  $\text{valid\_from} \leq d < \text{valid\_to}$ 인 반개구간으로 정의하였다. 최종 temporal master는 212,970건이며, CURRENT 4,770건, EXPIRED 203,831건, FUTURE\_EFFECTIVE 1,704건과 공포·시행 경계에서 검색 대상에서 제외되어야 하는 superseded 상태를 포함한다. invalid interval, 동일 component의

복수 CURRENT, 시행 전 판본의 초기 CURRENT 분류는 모두 0건이었다.


시간정보의 법적 검증은 23개 규칙으로 수행하였다. PASS 22건, PASS WITH NOTE 1건, FAIL 0건이었으며, point-in-time 경계 표본 30건을 검토하였다. 예외 테이블에는 39,545건을 기록하였고, 파싱된 범위 안에서 해결되지 않은 시간 예외는 0건이었다. 단, 동결 원천자료에 포함되지 않은 기술기준 과거 첨부파일 6건은 비검색 COVERAGE\_GAP으로 유지하였다.

구조와 개정관계는 의미적 유사도로 생성하지 않고 원문에 명시된 근거만 사용하였다. 연속 판본 196,293쌍에서 26,431개의 기계적 diff를 생성한 뒤 6,058개의 개정행위와 CREATES, TERMINATES, SUPERSEDES 관계 18,174개를 구성하였다. 별도로 상·하위 위임 및 시행관계 875개(DELEGATES\_TO 658개, IMPLEMENTS 217개)를 근거문언과 source locator에 연결하였다. 관계는 relation ID, 유효기간, 근거 version 및 검토상태를 포함하며, LLM이 추론한 관계는 실험용 graph의 확정 edge로 채택하지 않는다.

### 3.7 검색단위 생성과 청킹 후보 비교

정제된 법령본문, 구조화된 별표·기술기준 요건, 시간 metadata, hierarchy metadata, 개정행위 및 검증된 법률관계를 공통 검색단위인 Text Unit으로 변환하였다. 최종 TT19-TEXTUNIT-v1.1에는 61,239개 Text Unit이 포함된다. 구성은 CONTENT 22,146개, ACTION 6,058개, TEMPORAL\_METADATA 10,014개, HIERARCHY\_METADATA 22,146개, DELEGATION\_RELATION 658개, IMPLEMENTATION\_RELATION 217개이다.

## Incremental comparison logic for Systems A-D



All systems share the final chunk corpus, embedding model, reranker, prompt, LLM, and evidence budget.

**그림 2 A-B-C-D 단계적 비교논리 (Incremental comparison logic for Systems A-D)**  
CONTENT에는 법령본문 8,011개와 구조화 요건 14,135개가 포함된다. 각 Text Unit에는 norm, component, version, 유효기간, 구조경로, 원천 포인터, provenance와 검색대상 여부를 저장하였다.

초기 Text Unit에서는 항·호 등 leaf 내용은 존재하지만 법 제55조와 시행규칙 제121조처럼 상위 조문의 고유 본문이 누락되는 문제가 확인되었다. 이를 보완하여 부모 고유본문 1,189건과 대응하는 시간·계층 metadata를 복구하였다. 자식 내용과 겹치는 부분은 원문 범위를 분리하고 제목만 있거나 비어 있는 부모는 검색단위로 추가하지 않았다. 복구 전 corpus와 실행증빙은 보존하고, 복구본은 FRZ-TT19-002로 별도 동결하였다.

청크는 한 가지 방식을 선택적으로 선택하지 않고 8개 후보를 동일 Text Unit에 적용하였다. 후보별 원문 포함성, 결정론적 재생성, 청크수, 그리고 승인된 파일럿 20문항에서 Recall@5, MRR@10 및 Hit@10을 비교하였다. 생성모델 성능은 청크 선정에 사용하지 않아 retrieval unit 선택과 답변 생성의 영향을 분리하였다.

승인된 Q001-Q020 Gold를 이용한 비교에서 structural\_article\_paragraph가 Recall@5 0.5700, MRR@10 0.5833, Hit@10 0.8000으로 가장 높았다. 청크 수는 15,654개로 22,146개 수준의 일반 component 후보보다 약 29% 적었으며, Recall@5는 2위보다 10.5%p 높았다. 따라서 이 전략을 FRZ-TT21-001로 동결하고 네 시스템의 공통 입력으로 사용한다. Q014와 Q017-Q020에

서 남은 관계·시간 검색 한계는 청크를 재조정하여 제거하지 않고 후속 시스템 비교에서 관찰할 오류유형으로 유지하였다.

## 3.8 임베딩과 검색 인덱스

최종 15,654개 청크는 BAAI/bge-m3의 동일 revision을 사용하여 1,024차원 dense vector로 변환하였다. fp32와 fp16 smoke test에서 차원, NaN, Inf 및 all-zero vector를 검사한 뒤 fp16을 사용하였다. 전수 인코딩 후 입력 청크와 embedding의 1:1 대응을 확인하고, Milvus Lite의 aviation\_law\_chunks collection에 15,654건을 적재하였다. 각 vector에는 chunk\_id, norm\_id, component\_id, version\_id, valid\_from, valid\_to, scope\_status 및 provenance pointer를 metadata로 연결하였다.

공통 검색모듈은 query embedding, vector retrieval, candidate top-k 및 BAAI/bge-reranker-v2-m3 reranking을 네 시스템에 동일하게 제공한다. graph index는 Norm, Component, component-time-version, Action 및 Text Unit node와 hierarchy, version, amendment, delegation 및 implementation edge로 구성한다. 다만 기존 Neo4j 구축본은 TT19 v1.0 기반이므로, 본실험 전에 TT19 v1.1의 61,239개 Text Unit과 동기화하고 duplicate edge, dangling edge, cycle, invalid temporal edge 및 relation evidence를 다시 전수검사한다. 이 재구축·QA gate를 통과하지 않은 graph 결과는 확증실험에 사용하지 않는다.

표 7 비교시스템의 조작적 정의 (Operational definitions of the four systems)

| 시스템                 | 검색 코퍼스  | 시간통제                  | 구조 관계                | 주요 비교           |
|---------------------|---------|-----------------------|----------------------|-----------------|
| A Current Vector    | 현재 유효판본 | corpus cutoff 외 별도 없음 | 없음                   | 현행질문 기준선        |
| B All-Version Naive | 모든 판본   | 없음                    | 없음                   | A-B: 판본혼합 영향    |
| C Temporal-Filtered | 모든 판본   | query-date 유효구간       | 없음                   | B-C: 시간필터 순효과   |
| D SAT-Graph RAG     | 모든 판본   | query-date 유효구간       | 검증 관계의 제한적 traversal | C-D: 구조탐색 추가 효과 |

### 3.9 비교 시스템과 통제 조건

System A는 기준일 현재 유효한 판본만 포함하는 Current Vector RAG이다. System B는 모든 과거·현재·미래시행 판본을 하나의 index에서 검색하되 시간필터를 적용하지 않는다. System C는 System B와 같은 multi-version corpus를 사용하지만, 질문의 as\_of\_date 또는 사전에 정한 평가기준일에 대해 valid\_from ≤ query\_date < valid\_to를 만족하는 판본만 후보로 허용한다. System D는 System C의 유효판본 seed를 유지한 상태에서 검증된 hierarchy, delegation, implementation, amendment 및 approval-dependency 관계를 제한된 hop과 evidence budget 안에서 확장한다. graph가 추가근거를 찾지 못한 경우 System C의 temporal seed를 버리지 않는 fallback을 적용한다.

### 3.10 평가문항과 Gold Standard

평가문항은 청킹과 설정을 결정하기 위한 파일럿 20문항과 최종 성능평가를 위한 hold-out 문항으로 구분한다. 파일럿 Q001-Q020은 직접 조문, 별표·수치, 상·하위 위임관계, 조문·별표 관계, 과거시점, 유효기간 및 미래시행 유형을 포함한다. 파일럿 문항과 Gold는 청킹 후보 비교 전에 승인·고정하였으며, 후보 성능을 본 뒤 질문이나 정답근거를 수정하지 않았다. 최종평가에서는 별도의 후보문항을 전문가가 내용적절성, 답변가능성, 근거충족성 및 난이도 측면에서 검토한 뒤 hold-out을 확정한다.

각 문항의 Gold Standard에는 question\_id, question text, as\_of\_date, answerability, gold answer, required evidence, alternative valid evidence, required evidence count, 정답

component와 version, forbidden version 및 허용 가능한 기권조건을 포함한다. 동일한 법적 결론을 지지하는 복수 경로가 있는 경우 하나의 document ID만을 정답으로 강제하지 않고 전문가가 승인한 대체근거를 등록한다. 반면 상위 위임근거, 적용 시점의 판본 또는 수치 조건처럼 결론에 반드시 필요한 근거는 required evidence로 구분한다.

### 3.11 평가지표와 통계분석

검색성능은 Hit@K, Recall@K, MRR@K와 nDCG@K로 평가한다. 다중근거 문항에는 required evidence 부분충족률과 완전충족률을 추가한다. 시간정합성은 적용 version의 정확성, forbidden-version retrieval rate, forbidden-version citation rate 및 query-date 유효성으로 측정한다. 생성답변은 정확성, 시간정합성, 근거충실성, 인용정확성·완전성, 환각 및 적절한 기권을 평가한다. 전체 답변뿐 아니라 독립적으로 검증 가능한 claim 단위로 evidence entailment를 판정한다.

효율성은 end-to-end latency, retrieval, rerank, graph, generation 단계별 latency, token 사용량, 질문당 비용, index 구축시간 및 저장용량으로 비교한다. 동일 문항이 네 시스템에서 반복되므로 paired design을 사용한다. 이분형 결과는 전체 시스템 차이를 먼저 검정한 뒤 보정된 사후 paired comparison을 수행하고, 연속·서열형 지표는 분포와 가정을 확인해 반복측정 모수 또는 비모수 검정을 선택한다. 효과크기와 95% 신뢰구간을 p-value와 함께 보고한다.

### 3.12 재현성 관리와 본 실험 동결 조건

재현성을 위해 모든 run은 질문집과 Gold의

표 8 평가영역과 핵심지표 (Evaluation dimensions and primary metrics)

| 평가영역   | 핵심지표                                                   | 판정단위                | 주요 오류                             |
|--------|--------------------------------------------------------|---------------------|-----------------------------------|
| 검색 정확도 | Hit@K, Recall@K, MRR@K, nDCG@K                         | 질문·필수근거             | retrieval miss, rank failure      |
| 근거 완전성 | required-evidence partial/full coverage                | 다중근거 질문             | incomplete evidence               |
| 시간정합성  | Version Accuracy, forbidden-version retrieval/citation | 질문·인용               | temporal misgrounding             |
| 생성품질   | answer correctness, claim support, faithfulness        | 답변·claim            | unsupported or contradicted claim |
| 인용품질   | citation accuracy and completeness                     | claim-evidence pair | wrong or missing citation         |
| 답변거절   | appropriate abstention / false abstention              | 질문                  | unanswerable-control error        |
| 효율성    | latency, tokens, cost, storage                         | run-system          | resource overhead                 |



그림 3 항공안전법령 corpus 변환 파이프라인

표 9 원문 수집 및 전처리 결과

| 단계                         | 단위   | 결과                   | QA 판정            |
|----------------------------|------|----------------------|------------------|
| Raw corpus                 | 파일   | 99 (XML 95, PDF 4)   | 전수 QA PASS       |
| Semantic document versions | 법령 판 | 93                   | Hash 93/93 PASS  |
| Norms                      | 법규범  | 4                    | ID 충돌 0          |
| Parsed components          | 구성요소 | 239,509              | Idempotency PASS |
| Cleaned components         | 구성요소 | 239,509              | 행 손실 0           |
| Normalized components      | 구성요소 | 67,161               | 의미손실 0           |
| NFKC changed               | 구성요소 | 51,695               | 법률·교차참조 이슈 0     |
| Structured Appendix 18     | 구조행  | 1,567                | 30건 표본 PASS      |
| Operations requirements    | 요건   | 15,751 (검색범위 14,135) | 범위누수 0           |

hash, raw·cleaning·temporal·Text Unit·chunk freeze ID, code commit 또는 script hash, mode revision, config hash, index manifest, 실행시각, random seed 및 output hash를 기록한다. 단계별 산출물은 기존 파일을 덮어쓰지 않고 versioned artifact로 보존한다. 오류를 수정한 경우 변경 전 산출물과 실패 원인을 남기고 새로운 freeze ID를 발급한다.

확증실험은 다음 조건을 모두 충족한 뒤 시작한다. 첫째, TT19 v1.1 기반 final chunk와 vector index의 수량·ID·metadata가 일치해야 한다. 둘째, Neo4j graph를 동일 corpus로 갱신하고 duplicate·dangling·cycle·temporal·edge·relation·evidence QA를 통과해야 한다. 셋째, A-D가 동일한 공통 생성계약으로 재실행되어야 한다. 넷째, 최종 Gold와 forbidden version이 전문가 검토를 거쳐 동결되어야 한다. 다섯째, 설정용 파일럿과 hold-out을 엄격히 분리해야 한다. 이 조건을 충

족하지 않은 live pilot 결과는 실행전정정 점검에만 사용하고, 연구가설의 최종 검증값으로 보고하지 않는다.

## IV 연구결과

### 4.1 결과 제시 범위

본 장은 연구관리 대시보드와 동결기록을 기준으로 결과를 구분하였다. 원문corpus 수집과 품질검사, 법령구조·시간정보 복원, 개정행위 연결, Text Unit 생성, 청킹 후보 비교, 임베딩·Vector DB·Graph DB 구축은 완료된 결과로 기술하였다. 20문항A-D 실행은 기술적 실행전정정을 확인한 개발 파일럿이므로 연구가설의 효과검정 결과로 사용하지 않았다. 최종 연구결과가 되려면 전문가 검토를 거쳐 80문항 Holdout을 동결하고, 동일 조건에서 A-D를 실행

표 10 조문버전의 시간상태 분포

| 시간상태                  | 건수      | 비율      | 해석         |
|-----------------------|---------|---------|------------|
| EXPIRED               | 203,831 | 95.71%  | 과거 유효본     |
| CURRENT               | 4,770   | 2.24%   | 기준일 현재 유효본 |
| FUTURE_EFFECTIVE      | 1,704   | 0.80%   | 공포 후 시행 전  |
| SUPERSEDED_SAME_DAY   | 2,552   | 1.20%   | 동일 일자 내 대체 |
| AT_EFFECTIVE_BOUNDARY | 25      | 0.01%   | 시행경계 대체    |
| BEFORE_EFFECTIVE      | 1       | <0.01%  | 시행 전 대체    |
| PRE_EFFECTIVE_COPY    | 87      | 0.04%   | 시행 전 복제상태  |
| 합계                    | 212,970 | 100.00% |            |

표 11 개정행위 최종 분류 결과

| 개정행위 분류                 | 건수    | 비율      |
|-------------------------|-------|---------|
| NON_SUBSTANTIVE         | 3,359 | 55.45%  |
| TEXTUAL_MODIFICATION    | 2,335 | 38.55%  |
| PROVISION_TERMINATED    | 118   | 1.95%   |
| NUMERIC                 | 106   | 1.75%   |
| SCOPE_CHANGED           | 97    | 1.60%   |
| MIXED                   | 33    | 0.54%   |
| PROVISION_CREATED       | 7     | 0.12%   |
| OBLIGATION_RELAXED      | 2     | 0.03%   |
| OBLIGATION_STRENGTHENED | 1     | 0.02%   |
| 합계                      | 6,058 | 100.00% |

행한 뒤 FINAL\_METRICS와 STATISTICS에 결과를 기록해야 한다.

## 4.2 항공안전법령 corpus 구축결과

동결된 Raw Dataset V1은 99개 파일로 구성되었다. XML 95개와 PDF 4개를 전수 검사한 결과, 0-byte 파일, 파일손상 및 XML syntax 오류는 발견되지 않았다. 현행 end point와 최신 연혁본 사이에 동일 hash를 가진 2쌍은 수집오류가 아니라 의도된 alias로 기록하였다. 원문 99개는 semantic document version 93개와 법 규범 4개로 구조화되었고, parser는 239,509개의 component를 생성하였다. 동일 입력을 두 차례 처리한 결과dataset digest가 일치하여 parsing의 결정성이 확인되었다.

본문 정제에서는 239,509개 component가 동일한 행수로 유지되어 행 손실이 없었다. 67,161건에 normalization이 적용되었고 51,695건에서 NFKC 변화가 확인되었으나, 의미 있는 법률문언의 손실과 교차참조 훼손은 확인되지 않았다. 별표와 부칙은 일반 조문과 분리하여 구조보존 방식으로 처리하였다. 이 결과는 이후 성능차이가 원문 누락이나 비결정적 preprocessing에서 발생할 가능성을 줄이는 기반이 된다.

## 4.3 시간·버전 및 개정행위 구조화 결과

조문별 시간 master는 212,970개의 provision version으로 구성되었다. 그 중 EXPIRED가 203,831건으로 대부분을 차지했고, CURRENT 4,770건, FUTURE\_EFFECTIVE 1,704건이 확인되었다. 같은 날 대체된 버전과 시행경계에서 교체된 버전도 별도 상태로 보존하였다. invalid interval, 하나의 component에 대한 복수 CURRENT, 시행일 이전의 premature FUTURE는 모두 0건이었다. 이는 all-version corpus가 현행 조문보다 과거 조문을 압도적으로 많이 포함하며, 시간필터가 없는 System B에서version mixing 가능성이 구조적으로 높다는 것을 보여준다. 다만 이것은 H1의 성능검정 결과가 아니라 corpus 구성에 근거한 위험조건이다.

연속 버전 비교에서는 199,854개의 후보 후속 관계 중 법적으로 연속된 196,293쌍을 확정하였다. 이 중 변경된 쌍은 6,058건, 변경되지 않은 쌍은 190,235건이었다. 6,058개의 변경 쌍마다 amendment action 1건을 생성하고 CREATES, TERMINATES, SUPERSEDES 관계를 각각 6,058건씩 연결하였다. 초기 자동분류에서는 숫자, 의무강화·완화 및 삭제표지에 대한 오분류가

반복되어 11차례의 classifier 보정과 756건의 review queue 검토를 수행하였다. 최종적으로 755건은 기존 분류를 승인하고 1건을 수동 재분류하여 unresolved와 review\_required를 0건으로 줄였다. 이는 법률관계의 자동추출이 단순한 문자열 차이보다 법적 검토에 크게 의존한다는 결과이다.

#### 4.4 Text Unit과 청킹결과

부모 본문의 과소분할을 수정한 TT19 v1.1에서는 61,239개의 Text Unit을 생성하였다. CONTENT와 HIERARCHY\_METADATA가 각각 22,146건으로 가장 많았고, TEMPORAL\_METADATA 10,014건, ACTION 6,058건, DELEGATION\_RELATION 658건, IMPLEMENTATION\_RELATION 217건이 포함되었다. 초기 corpus보다 3,567개가 증가했으며, 항공안전법 제55조와 시행규칙 제121조 등 누락된 부모 본문이 복구되었다. 이 변경은 Q001과 Q014처럼 부모 조문과 하위근거를 함께 요구하는 질문의 검색 가능성을 회복하였다.

표 12 Text Unit 구성

| Text Unit 유형            | 건수     | 주요 기능         |
|-------------------------|--------|---------------|
| CONTENT                 | 22,146 | 법령 본문과 구조화 요건 |
| HIERARCHY_METADATA      | 22,146 | 법령·조문 위계정보    |
| TEMPORAL_METADATA       | 10,014 | 유효기간과 버전 상태   |
| ACTION                  | 6,058  | 개정행위 설명       |
| DELEGATION_RELATION     | 658    | 위임관계          |
| IMPLEMENTATION_RELATION | 217    | 이행·적용관계       |
| 합계                      | 61,239 |               |

TT20에서는 8개의 청킹 후보를 생성하여 승인된 Q001 - Q020 Gold 문항으로 동일 조건에서 비교하였다. 최종 선정된 structural\_article\_paragraph는 같은 법령판과 조문 내부의 항·호를 구조적으로 병합하되 512 token을 초과할 경우 원문단위 경계에서 분리한다. 이 전략은 15,654개 청크를 생성하여 일반 후보보다 약 29% 적은 index 규모를 유지하면서 Recall@5 57.0%, MRR@10 58.3%, Hit@10 80.0%로 가장 높은 결

과를 보였다. Recall@5는 2위 후보보다 10.5%p 높았다.

표 13 청킹 후보별 생성 청크 수

| 청킹 전략                        | 청크 수   | 최종 선정         |
|------------------------------|--------|---------------|
| fixed_512                    | 22,155 |               |
| fixed_512_overlap50          | 22,155 |               |
| fixed_char_lbrag             | 22,146 |               |
| recursive_paragraph_sentence | 22,155 |               |
| structural_component         | 22,146 |               |
| structural_article_paragraph | 15,654 | 선정            |
| appendix18_row               | 1,594  | 별표 특화 후보      |
| appendix36_technical         | 12,541 | 별표·기술기준 특화 후보 |

문항별 분석에서는 구조보존 청킹의 장점과 한계가 함께 나타났다. Q001에서는 부모본문 복구와 구조단위 병합으로 Gold 3건 모두 Top-5에 검색되었으나, 일반 후보는 Top-10에서 1건만 검색하였다. Q014에서는 시행규칙 제121조가 Top-2에 검색되었지만 상위법인 항공안전법 제55조는 Top-10에 포함되지 않아 vector similarity만으로 상·하위 규범을 함께 회수하기 어렵다는 점이 확인되었다. Q017 - Q020의 시점질문은 모든 청킹 후보가 Gold를 회수하지 못했다. 이는 청킹만으로 시간질문을 해결할 수 없고 조문번호 기반 보완검색과 temporal filtering이 필요함을 보여 준다.




그림 4 최종 청킹 전략의 검색성능

#### 4.5 검색인프라 및 A - D 기술파일럿

최종 15,654개 청크는 BGE-M3 fp16으로 인코딩되었으며, 각 vector의 차원은 1,024였다. 전체 vector는 Milvus collection에 동일 건수로 적재되었고 top-1 self-check를 통과하였다. SAT-Graph

Retrieval infrastructure implemented before the holdout experiment




그림 5 Holdout 실험 전 검색 인프라 구축결과  
표 14 Vector DB와 SAT-Graph 구축 결과

| 구성요소             | 구축 결과                             | QA 결과                                  |
|------------------|-----------------------------------|----------------------------------------|
| BGE-M3 embedding | 15,654 vectors; 1,024 dimensions  | NaN/Inf/zero 없음                        |
| Milvus           | 15,654 rows                       | 적재건수 일치; search self-check PASS        |
| Neo4j SAT-Graph  | 289,575 nodes; 485,907 edges      | dangling/cycle/invalid temporal edge 0 |
| 공통 retrieval     | query - embed - retrieve - rerank | seed self-check rank 1                 |

표 15 A - D 20문항 기술 파일럿 운영지표

| System              | 처리    | Abstention | Error | 평균 token | 평균 latency |
|---------------------|-------|------------|-------|----------|------------|
| A Current Vector    | 20/20 | 6          | 0     | 3,079.6  | 26.600 s   |
| B All-Version Naive | 20/20 | 15         | 0     | 2,833.9  | 19.665 s   |
| C Temporal-Filtered | 20/20 | 5          | 0     | 3,079.8  | 26.295 s   |
| D SAT-Graph         | 20/20 | 5          | 0     | 3,127.0  | 26.846 s   |

표 16 A - D Holdout 검색성능 비교

| System | N | Hit@5 | Recall@5 | MRR@10 | nDCG@10 | Evidence completeness |
|--------|---|-------|----------|--------|---------|-----------------------|
|        |   |       |          |        |         |                       |
|        |   |       |          |        |         |                       |
|        |   |       |          |        |         |                       |

표 17 B - C 시간성능 비교

| System | N | Version Accuracy | Temporal consistency | Forbidden-version retrieval | Forbidden-version citation |
|--------|---|------------------|----------------------|-----------------------------|----------------------------|
|        |   |                  |                      |                             |                            |
|        |   |                  |                      |                             |                            |
|        |   |                  |                      |                             |                            |

표 18 C - D 구조정보 추가효과

| 질문유형 | System C | System D | 차이 | 95% CI | Effect size | 보정 p-value |
|------|----------|----------|----|--------|-------------|------------|
|      |          |          |    |        |             |            |
|      |          |          |    |        |             |            |
|      |          |          |    |        |             |            |

표 19 A - D 생성답변 품질

| System | Answer correctness | Temporal consistency | Citation accuracy | Citation completeness | Hallucination | Appropriate abstention |
|--------|--------------------|----------------------|-------------------|-----------------------|---------------|------------------------|
|        |                    |                      |                   |                       |               |                        |
|        |                    |                      |                   |                       |               |                        |
|        |                    |                      |                   |                       |               |                        |

는 TT19 본문복구를 반영하여 289,575개 node와 485,907개 edge로 재구축되었다. dangling edge, version cycle 및 invalid temporal edge는 0건이었으나 duplicate edge 856건과 REVIEW\_REQUIRED CTV 4,137건이 QA 주의 사항으로 남았다. 따라서 graph가 기술적으로 구축되었다는 사실과 graph의 모든 법적 관계가 최종 검토되었다는 판단은 구분해야 한다.

TT28-GENERATION-v1.2를 적용한 20문항 재실행에서 A - D 모두 runtime error 없이 20문항을 처리하였다. 그러나 abstention 수는 System A 6건, B 15건, C 5건, D 5건으로 차이가 났다. 평균 latency는 B가 19.665초로 가장 짧고 D가 26.846초로 가장 길었다. 이 수치는 Gold 정답과의 일치도, Version Accuracy 또는 인용완전성을 반영하지 않는다. 특히 파일럿은 법률·도메인 검토가 완료되기 전에 override 방식으로 동결되었으므로, 다음 표는 연구성능이 아니라 실험건전성과 실험설계 점검 결과로만 해석하였다.

#### 4.6 A - D 최종성능비교

다음 표와 Figure는 TT33 - TT38이 완료된 후 입력한다. 수치가 확정되기 전에는 본문에서 System C 또는 D의 우월성, H1 - H3의 지지여부 및 통계적 유의성을 진술하지 않는다.

#### 4.7 확정 결과 요약

현재까지 확정된 결과는 네 가지이다. 첫째, 99개 원문으로부터 212,970개의 조문버전과 61,239개의 Text Unit을 재현 가능하게 구축하였다. 둘째, all-version corpus의 95% 이상이 과거 유효본으로 구성되어 시간필터 없는 검색에서 버전혼입 위험이 크다는 구조적 조건을 확인하였다. 셋째, 구조보존 청킹이 20문항 파일럿에서 Recall@5 57.0%, MRR@10 58.3%, Hit@10 80.0%로 가장 높았으며 index 규모도 일반 후보보다 작았다. 넷째, Vector DB와 SAT-Graph 및 네 시스템의 기술 실행은 가능했지만, 최종 성능과 가설은 Holdout 및 전문가 평가 전에는 판단할 수 없다.

### V 결론 및 시사점

#### 5.1 데이터 품질과 구조복원의 의미

본 연구의 첫 번째 시사점은 항공안전법령 RAG의 성능문제가 검색기나 LLM의 선택 이전에 corpus construction에서 시작된다는 점이다. 초기 Text Unit에서 부모 본문이 누락되었을 때 법 제55조와 시행규칙 제121조처럼 질문의 핵심 근거가 검색대상에서 사라졌다. 본문 복구 후 Q001에서 Gold 3건이 Top-5에 회수된 결과는 전처리 오류가 retrieval architecture의 성능으로 오인될 수 있음을 보여 준다. 따라서 법령 RAG 연구는 원문파일 수나 청크 수만 보고할 것이 아니라, component 보존, 부모 - 자식 연결, 별표구조, 유효기간 및 원문 provenance의 QA 결과를 함께 제시해야 한다.

개정행위 분류에서도 같은 문제가 확인되었다. 숫자나 '하여야 한다'와 같은 표면표현만 사용하면 편집상 숫자, 날짜, OCR 분리 및 삭제표지를 실질적 의무변경으로 오분류할 수 있었다. 최종분류에 이르기까지 11차례 보정과 756건 전수검토가 필요했다는 사실은 구조화 된 graph가 항상 원문보다 신뢰성이 높은 것은 아님을 의미한다. de Martim(2025)이 경고한 upstream data-quality dependence가 국내 항공법령 구축과정에서도 실제 운영문제로 나타났다.

#### 5.2 구조 보존 청킹의 효과와 한계

structural\_article\_paragraph 전략은 fixed, recursive 및 단일 component 전략보다 높은 검색성과 작은 index 규모를 동시에 보였다. 이는 조·항·호를 완전히 분리하면 조건, 본문과 단서가 흩어지고, 반대로 법령판 전체를 큰 청크로 만들면 관련 없는 규정이 포함되는 문제를 구조단위 병합이 완화했기 때문으로 해석할 수 있다. 특히 Q001의 개선은 상위 문맥을 보존하는 청킹이 항공법령의 최소 충분근거 회수에 유용하다는 것을 보여준다.

그러나 청킹만으로 모든 문제를 해결하지는 못했다. Q014에서 상위법과 시행규칙이 동시에 회수되지 않았고, Q017 - Q020의 시점질문은 모든 후보에서 실패하였다. 이러한 결과는 RQ1에

대해 잠정적으로 두 가지를 시사한다. 항공법령의 구조보존 청킹은 국소적 문맥 손실을 줄이지만, 문서 간 위임관계와 시간적 효력은 vector similarity 바깥의 명시적 제약이 필요하다. 최종 RQ1 답변은 Holdout에서 일반질문, 계층질문, 교차규정질문 및 시간질문의 오류율을 비교한 뒤 확정해야 한다.

### 5.3 Temporal Filtering과 SAT-Graph에 대한 논의

전체 212,970개 조문버전 중 CURRENT가 2.24%에 불과하고 EXPIRED가 95.71%라는 분포는 System B의 검색공간이 과거 유효본에 의해 지배된다는 것을 보여 준다. 따라서 동일 조문 번호와 유사한 문언이 여러 버전에 존재할 때 의미유사도만으로 적용버전을 선택하기 어렵다. 이는 Cymbler et al.(2026)의 temporal misgrounding과 일치하는 조건이며 System C를 별도 비교조건으로 두어야 하는 경험적 근거가 된다. 다만 corpus 분포만으로 C의 우월성을 결론내릴 수 없고, B - C Holdout 비교에서 Version Accuracy와 forbidden-version rate를 측정해야 한다.

System D의 필요성도 청킹 파일럿에서 관찰되었다. Q014처럼 상위법과 시행규칙을 함께 요구하는 질문에서 관련 하위조문은 검색되었지만 상위법이 누락되었다. 이는 verified delegation, implementation 및 hierarchy edge를 따라 근거를 확장할 가능성을 보여 준다. 동시에 graph 구축과정에서는 duplicate edge 856건, REVIEW\_REQUIRED CTV 4,137건 및 초기 graph-scope-empty 문제가 발견되었다. 따라서 D의 추가효과는 graph를 사용했다는 사실이 아니라, 올바른 관계가 필요한 질문에서 근거완전성이 실제로 향상되고 그 이득이 오류·지연시간·운영비용을 상쇄하는지로 판단해야 한다.

20문항 기술 파일럿에서 System B의 abstention이 15건으로 많고 D의 latency가 가장 길었지만, 이를 H1 또는 H3의 증거로 해석해서는 안 된다. 해당 실행은 연구효과가 아니라 생성계약과 runtime health를 점검하기 위한 것이

있고, 법률·도메인 검토와 Gold scoring이 완료되지 않았다. 본 연구의 가설판정은 Table 4-9부터 Table 4-13에 Holdout 결과가 채워진 이후에만 가능하다.

### 5.4 학술 및 실무적 시사점

학술적으로 본 연구는 version-aware retrieval과 structure-aware retrieval을 하나의 복합시스템으로 묶지 않고 B - C와 C - D 비교로 분리한다. 이를 통해 시간정보의 효과와 법령구조의 추가 효과를 독립적으로 추정할 수 있다. 또한 forbidden version, 필수근거집합, citation completeness 및 최초 오류발생단계를 함께 기록함으로써 단일 정답률로는 보이지 않는 법률 RAG의 실패를 분석할 수 있다. 전처리, 청킹, temporal master, graph 및 실행결과를 hash와 manifest로 연결한 점도 재현성과 감사가능성을 높인다.

실무적으로는 법령RAG를 구축할 때 최신 LLM이나 GraphRAG를 먼저 선택하기보다 원문 범위와 버전정책을 확정하고, 조문과 별표의 구조보존 여부를 검증해야 한다. 항공안전 분야에서는 답변을 자동 의사결정으로 사용하기보다 적용버전, 상·하위근거, 원문위치 및 불확실성을 함께 제시하는 검토지원 도구로 운영할 필요가 있다. 특히 국제기준 반영과 국내 개정이 빠른 영역에서는 corpus 갱신 때마다 validity interval과 amendment edge를 재검증하고, graph에 새 관계를 추가할 때 원문근거와 검토 이력을 남겨야 한다.

## References

1. Ahn, H. B., Heo, J., & Hwang, H. W. (2021). A study on the improvement of the administrative disposition system for airmans. *Journal of the Korean Society for Aviation and Aeronautics*, 29(4), 52 - 63. <https://doi.org/10.12985/ksaa.2021.29.4.052>
2. Chasandras, I. (2025). Retrieval augmented

- generation on regulatory documents [Bachelor's thesis, Athens University of Economics and Business].
3. Chen, Z., Zhang, Q., Xiang, Z., Wei, Z., Gao, L., Huang, X., Zhang, Z., & Su, J. (2026). LegalGraphRAG: Multi-agent graph retrieval-augmented generation for reliable legal reasoning. arXiv preprint arXiv:2605.28120.
  4. Chen, Z., Xu, C., Wang, D., Huang, Z., Dou, Y., Jiang, X., & Guo, J. (2024). RuleRAG: Rule-guided retrieval-augmented generation with language models for question answering. arXiv preprint arXiv:2410.22353.
  5. Cymbler, R., Guez, D., & Fabre, L. (2026). Temporal misgrounding in legal RAG: A versioned-corpus benchmark for French tax law. arXiv preprint arXiv:2608.09393.
  6. Das, S., Abualhaija, S., & Bianculli, D. (2026). Fine-grained claim-level RAG benchmark for law. arXiv preprint arXiv:2605.21071.
  7. de Martim, H. (2025). An ontology-driven Graph RAG for legal norms: A structural, temporal, and deterministic approach. arXiv preprint arXiv:2505.00039.
  8. Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., Metropolitansky, D., Ness, R. O., & Larson, J. (2024). From local to global: A GraphRAG approach to query-focused summarization. arXiv preprint arXiv:2404.16130.
  8. Guha, N., Nyarko, J., Ho, D. E., Ré, C., Chilton, A., Narayana, A., Chohlas-Wood, A., Peters, A., Waldon, B., Rockmore, D. N., et al. (2023). LegalBench: A collaboratively built benchmark for measuring legal reasoning in large language models. *Advances in Neural Information Processing Systems*, 36.
  9. Ha, S., Islam, M. R., Nanda, G., & Lercel, D. (2026). Reducing technician search burden: A multimodal RAG for Cessna 172 maintenance manual. Manuscript.
  10. Huwiler, D., Stockinger, K., & Fürst, J. (2025). VersionRAG: Version-aware retrieval-augmented generation for evolving documents. arXiv preprint arXiv:2510.08109.
  11. Immordino, G., & Vaiuso, A. (2026). A retrieval-augmented language assistant for unmanned aircraft safety assessment and regulatory compliance. arXiv preprint arXiv:2603.09999.
  12. Kalra, R., Wu, Z., Gulley, A., Hilliard, A., Guan, X., Koshiyama, A., & Treleaven, P. (2024). HyPA-RAG: A hybrid parameter adaptive retrieval-augmented generation system for AI legal and policy applications. arXiv preprint arXiv:2409.09046.
  13. Kim, S. M., Ahn, H. B., Yeo, U. J., & Hwang, H. W. (2023). A study on the judicial judgment of flight regulations under the Aviation Safety Act. *Journal of the Korean Society for Aviation and Aeronautics*, 31(3), 161 - 170. <https://doi.org/10.12985/ksaa.2023.31.3.161>
  14. Kim, T. S. (2023). Several problems of Article 57(1) of the Aviation Safety Act: Focusing on flight crew members. *HUFS Law Review*, 47(1). [In Korean]
  15. Korea Institute of Aviation Safety Technology. (2021). A study on improving the system of flight technical standards: Final report. [Research report, in Korean]
  16. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W. T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances*

- in Neural Information Processing Systems, 33, 9459 - 9474.
17. Li, H., Chen, Y., Hu, Y., et al. (2025). LexRAG: Benchmarking retrieval-augmented generation in multi-turn legal consultation conversation. arXiv preprint arXiv:2502.20640.
  18. Nagarajan, G., Kumar, O., & Santhiappan, S. (2025). PolicyBot: Reliable question answering over policy documents. arXiv preprint arXiv:2511.13489.
  19. Park, M., Oh, H., Choi, E., & Hwang, W. (2025). LRAGE: Legal retrieval augmented generation evaluation tool. arXiv preprint arXiv:2504.01840.
  20. Pipitone, N., & Alami, G. H. (2024). LegalBench-RAG: A benchmark for retrieval-augmented generation in the legal domain. arXiv preprint arXiv:2408.10343.
  21. Poliakov, M., & Shvai, N. (2024). Multi-Meta-RAG: Improving RAG for multi-hop queries using database filtering with LLM-extracted metadata. arXiv preprint arXiv:2406.13213.
  22. Sha, S. A. A., Sivanesan, S., Madasamy, A. K., & Binu, N. (2026). Rhetorical-role-aware retrieval-augmented generation for legal question answering over Indian Supreme Court judgments. arXiv preprint arXiv:2608.06828.
  23. Tang, Y., & Yang, Y. (2024). MultiHop-RAG: Benchmarking retrieval-augmented generation for multi-hop queries. arXiv preprint arXiv:2401.15391.
  24. Wang, X., Zhang, Y., Fan, W., Zhang, H., Wang, D., Yan, G., Mao, S., Shi, B., Lan, Y., & Cai, P. (2026). IA-RAG: Interval-algebra-driven temporal reasoning for dynamic knowledge retrieval. arXiv preprint arXiv:2606.06044.
  25. Wiratunga, N., Abeyratne, R., Jayawardena, L., Martin, K., Massie, S., Nkisi-Orji, I., Weerasinghe, R., Liret, A., & Fleisch, B. (2024). CBR-RAG: Case-based reasoning for retrieval augmented generation in LLMs for legal question answering. arXiv preprint arXiv:2404.04302.
  26. Yoo, T. J., Hwang, H. J., & Park, S. S. (2026). A study on establishing a just culture implementation framework in the aviation sector: Focusing on overseas legislation and responsibility judgment cases. Journal of the Korean Society for Aviation and Aeronautics, 34(2). [In Korean]
  27. Zhao, E., Taranukhin, M., Cui, W., Aikenhead, M., & Shwartz, V. (2026). CANLEGALRAGBENCH: Evaluating retrieval-augmented generation on Canadian case law. arXiv preprint arXiv:2605.30497.